第一讲 - 商务文本智能分析绪论

张建章

阿里巴巴商学院
杭州师范大学

2026-03-01

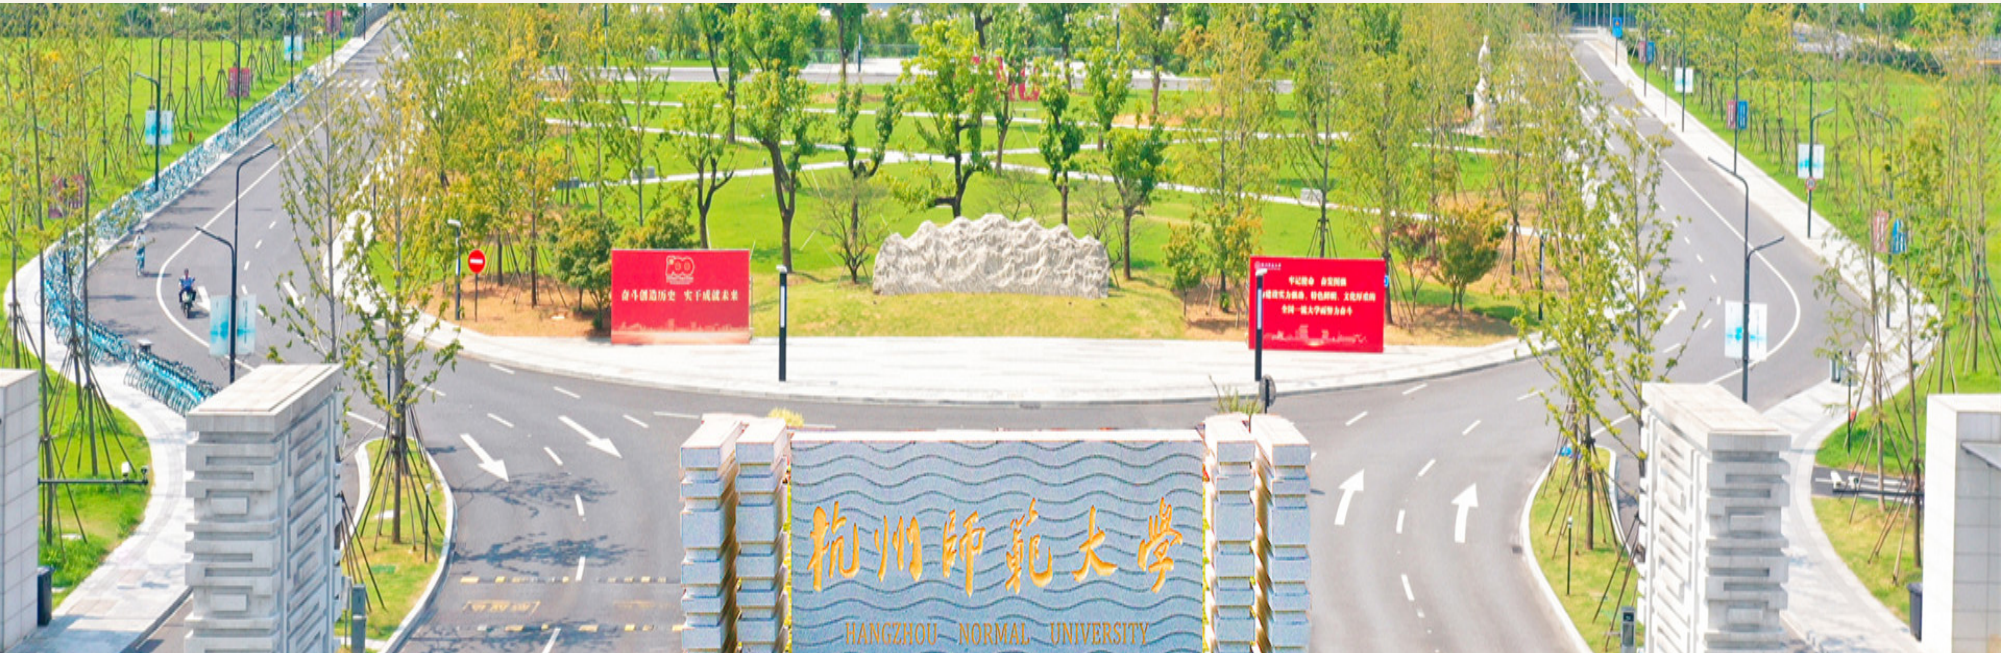

1 关于课程

2 文本挖掘概述

3 大语言模型及其应用

4 文本挖掘的基本流程

5 常见的文本挖掘任务

6 Kaggle注册与使用

7 课后实践

课程考核说明

根据教学大纲要求，本课程的考核办法为：

$$\begin{aligned}\text{总成绩} = \text{期末成绩} \times 50\% &+ \text{日常作业} \times 30\% \\ + \text{日常考勤} \times 10\% &+ \text{课堂表现} \times 10\%\end{aligned}$$

其中，期末考试采用**个人项目 (报告+实验材料)**形式。

课程简介

课程名称：《商务文本智能分析》

课程目标：

① **掌握文本挖掘的基本算法：**学习正则表达式、分词、编辑距离计算等基本工具，以及N-gram模型、逻辑回归分类、词嵌入向量、神经网络、文本聚类、主题模型等算法，理解这些基本工具和算法的原理。

② **掌握深度学习模型的文本挖掘应用：**理解RNN、LSTM、Transformer等模型模型的基本原理，掌握其在文本生成等任务中的应用。

③ **理解大模型的基本原理并了解典型应用：**大语言模型、掩码大语言模型、后训练（指令微调、对齐、测试时计算）和检索增强生成、多模态大语言模型、智能体。

④ **培养跨学科文本挖掘应用能力：**结合专业背景，应用文本挖掘技术进行商业数据分析和决策支持。

授课方式：课堂讲授 + 实践案例

实验环境

学习环境：一台能联网的电脑 + Chrome浏览器即可

其他环境：

- 编程语言：Python 3.X
- 在线环境：Kaggle或者魔搭社区
- 交互环境：Jupyter-lab
- 常用软件包：NLTK，spaCy，transformers，scikit-learn，matplotlib等
- 操作系统：Windows，Mac OS，Linux均可
- 开发环境：Anaconda + Linux/Mac OS + Pycharm/VS Code/TRAE...
- 学习资源：Kaggle (推荐)，Towards Data Science (推荐)，Stack Overflow (推荐)，Github (推荐)，CSDN，Reddit，阿里云天池，魔搭社区等

文本挖掘（Text Mining）是指从大量文本数据中提取有用信息和知识的过程，通常结合自然语言处理（NLP）和机器学习技术，旨在通过对文本数据的分析，发现潜在的模式、趋势和关联。文本挖掘包括但不限于文本预处理、信息提取、文本分类、文本聚类、主题建模等任务。

商学院同学学习文本挖掘的意义在于：

- **提升数据分析能力**：商学院学生可以通过文本挖掘技术分析市场趋势、消费者情感、竞争态势等非结构化数据，进而为决策提供数据支持。
- **优化商业决策**：通过情感分析、舆情监测等技术，能够分析客户反馈、产品评价等文本数据，帮助企业更好地理解顾客需求，优化产品和服务。
- **增强跨学科综合能力**：文本挖掘结合了计算机科学和商业知识，能够培养学生在大数据分析、市场调研、金融分析等领域的跨学科应用能力。
- **提升竞争力**：在数字经济时代，掌握文本挖掘技能的学生能够在大数据、人工智能等领域的商业应用中获得更强的竞争力。

文本挖掘最新进展

文本挖掘技术近年来取得了显著进展，主要体现在以下几个方面：

1. **深度学习的应用**：BERT、GPT等预训练语言模型的出现，显著提升了文本表示和理解能力，广泛应用于文本分类、情感分析等任务。
2. **多模态文本挖掘**：结合文本与图像、视频等其他模态数据，提升了复杂数据的处理能力，广泛用于图片和视频理解。
3. **迁移学习与领域自适应**：通过迁移学习，在特定领域或行业中减少对大规模标注数据的依赖，提升了文本挖掘的应用效果。
4. **图神经网络**：在文本关系网络建模中，图神经网络为社交网络分析、知识图谱构建等任务提供了新的解决思路。
5. **可解释性与公平性**：深度学习模型的可解释性和公平性问题，尤其在处理具有偏见内容时，已成为当前的研究热点。

大语言模型

大语言模型（Large Language Models, LLMs）是基于Transformer架构，利用海量文本数据进行预训练的自然语言处理模型。通过自监督学习，大语言模型能够理解和生成自然语言，执行包括文本生成、翻译、分类、问答等多种任务。其优越的语义理解能力和强大的迁移学习能力使其在各类语言任务中表现出色，成为当前人工智能领域的重要技术之一。

大语言模型的发展可以分为三个重要阶段：深度学习的引入与突破、Transformer模型的崛起、以及多模态和超大规模模型的发展。

1. 深度学习的引入与突破（2010s）

2013年，Google推出基于神经网络的神经机器翻译（NMT）模型，标志着深度学习在自然语言处理中的成功应用。2014年，Word2Vec通过词向量技术提升了文本表示能力，为大语言模型奠定了基础。

2. Transformer模型与大规模预训练的崛起（2017年以后）

2017年，谷歌提出Transformer模型，利用自注意力机制提高了模型处理序列数据的效率。2018年，OpenAI发布GPT，开启了大规模预训练语言模型的时代。Google的BERT（同年）采用双向编码技术，在NLP任务中取得了突破性进展。随后，GPT-2（2019年）和GPT-3（2020年）进一步提升了生成和理解能力。

3. 模型规模与多模态发展（2021年至今）

2021年，Google发布PaLM（5400亿参数），推动了超大规模模型的发展。2022年，ChatGPT基于GPT-3优化，广泛应用于实际对话场景。2023年，OpenAI发布GPT-4，具备了多模态处理能力，开启了大语言模型的新篇章。

4. 国内外大语言模型（2023年至今）

中国：复旦大学MOSS，阿里的通义千问，月暗之面的Kimi，深度求索的DeepSeek，字节跳动的豆包，智谱GLM，稀宇科技的MiniMax等。

国际：OpenAI的ChatGPT，谷歌的Gemini，Anthropic的Claude，xAI的Grok等，Meta的LLaMA，Mistral AI的Mistral等。

大语言模型时代下的商务文本智能分析

著名哲学家维特根斯坦说“*The limits of my language mean the limits of my world.*”，那么，对于《商务文本智能分析》来说，理解语言的边界，就是理解商业世界的边界。

语言（文本）在商业数据中占据着绝对的核心地位。让人类发明的机器能够像人类一样阅读、写作和交流，一直是人工智能领域面临的长期研究挑战。

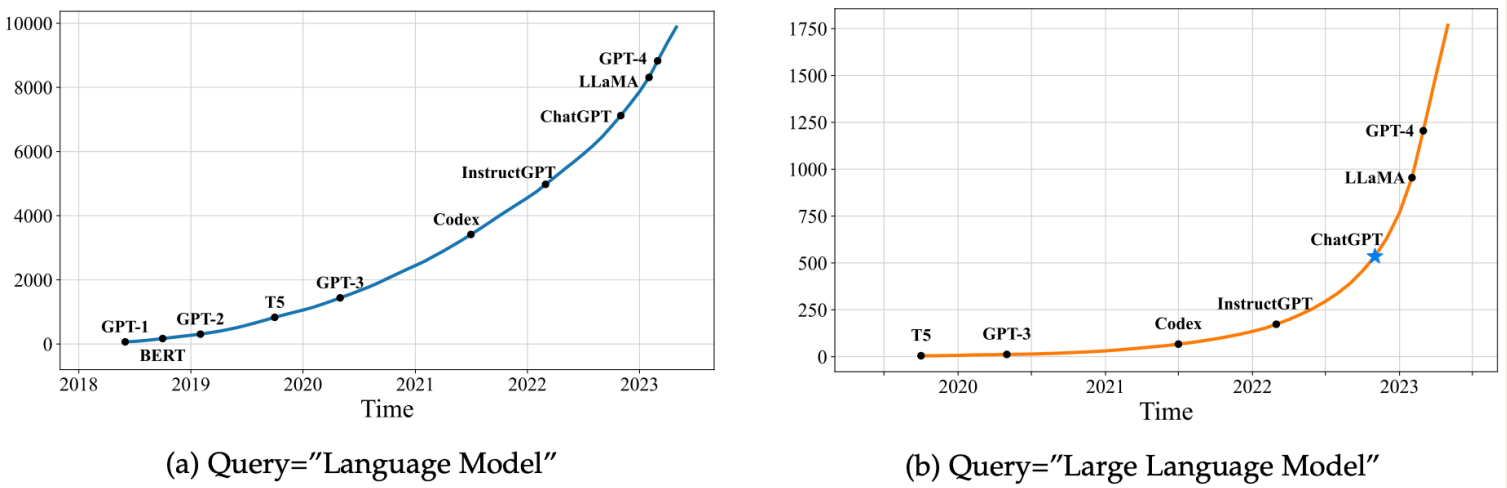

图 1: 包含关键词“语言模型”和“大型语言模型”的arXiv论文累计数量的趋势

随着大语言模型（LLMs）研究的爆发式增长（如上图所示），机器的自然语言理解能力实现了飞跃。掌握并应用这些模型，将极大拓展我们在数字经济中进行商务文本挖掘与决策的边界。

为什么商科学生需要懂大语言模型？

- 文本是商业世界中最大量、最复杂的非结构化数据（包含财报、新闻、用户评论、商业合同等）。
- 赋予机器人类水平的阅读、写作与沟通能力，一直是AI领域的研究目标。

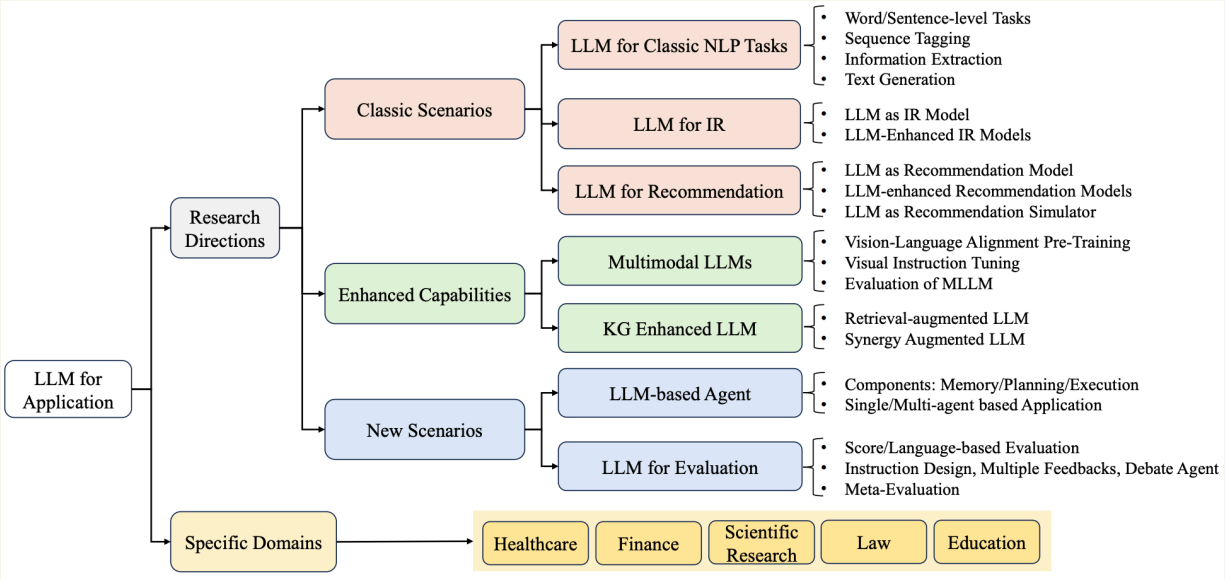

图 2: 大语言模型在典型研究方向与下游领域（如信息检索、推荐系统、金融等）的应用

LLM的出现正在引发一场技术革命，深刻重塑信息检索、推荐系统、金融分析等数字经济的核心应用场景。

语言模型发展的四个代际

核心趋势：从辅助特定任务向通用任务求解器的演进

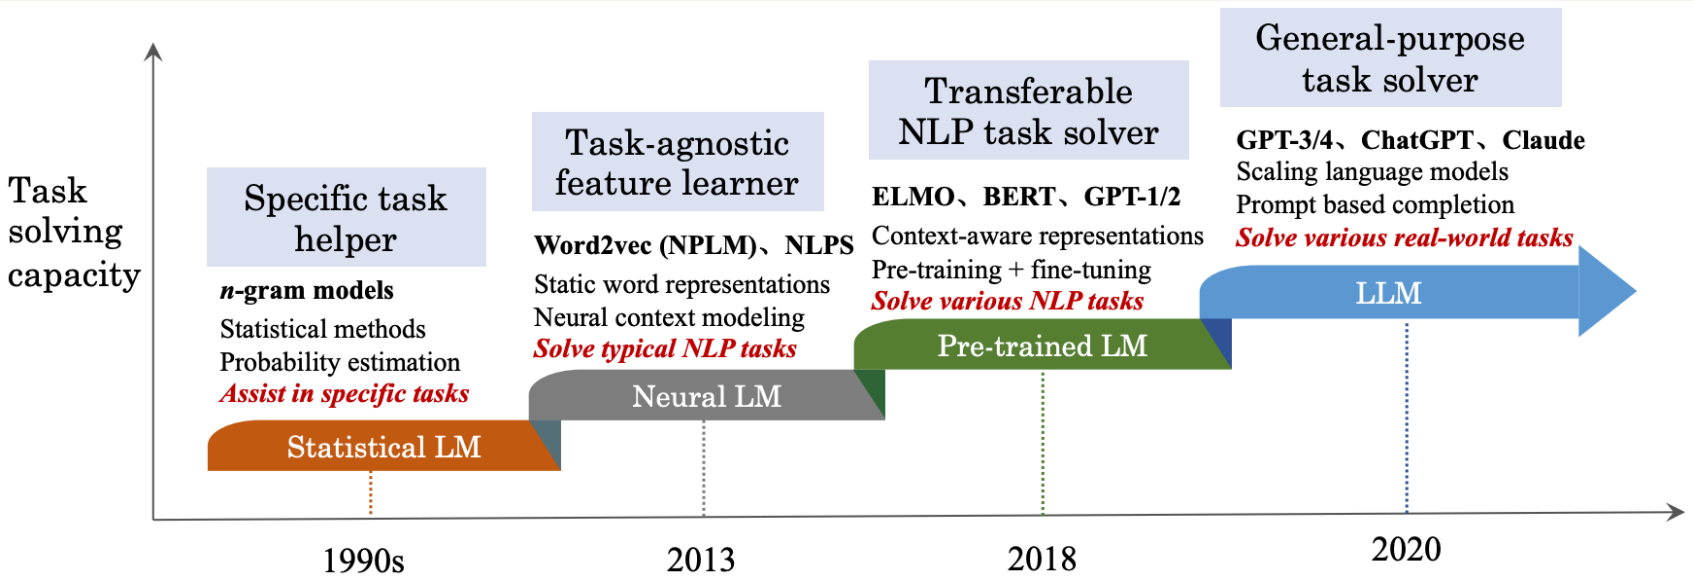

图 3: 从任务求解能力视角的四代语言模型演进过程

- **第一代：统计语言模型 (SLM)**。基于马尔可夫假设构建词预测模型，广泛用于信息检索和基础NLP任务，但受限于维度灾难导致的数据稀疏问题。
- **第二代：神经语言模型 (NLM)**。引入词的分布式表示（如Word2vec），通过神经网络刻画词序列概率，致力于学习任务无关的通用特征。

- **第三代：预训练语言模型 (PLM)**。以ELMo和BERT为早期代表，确立了“预训练加微调”的学习范式。通过在大规模无标签语料上学习上下文感知的词表示，极大提升了各项自然语言处理（NLP）任务的性能基准。
- **第四代：大语言模型 (LLM)**。研究发现模型扩展（Scaling）通常能带来性能提升。当参数规模与数据量突破一定阈值时，模型展现出小模型（如BERT）所不具备的“涌现能力”（Emergent Abilities）。代表模型包括175B参数的GPT-3与540B参数的PaLM等。

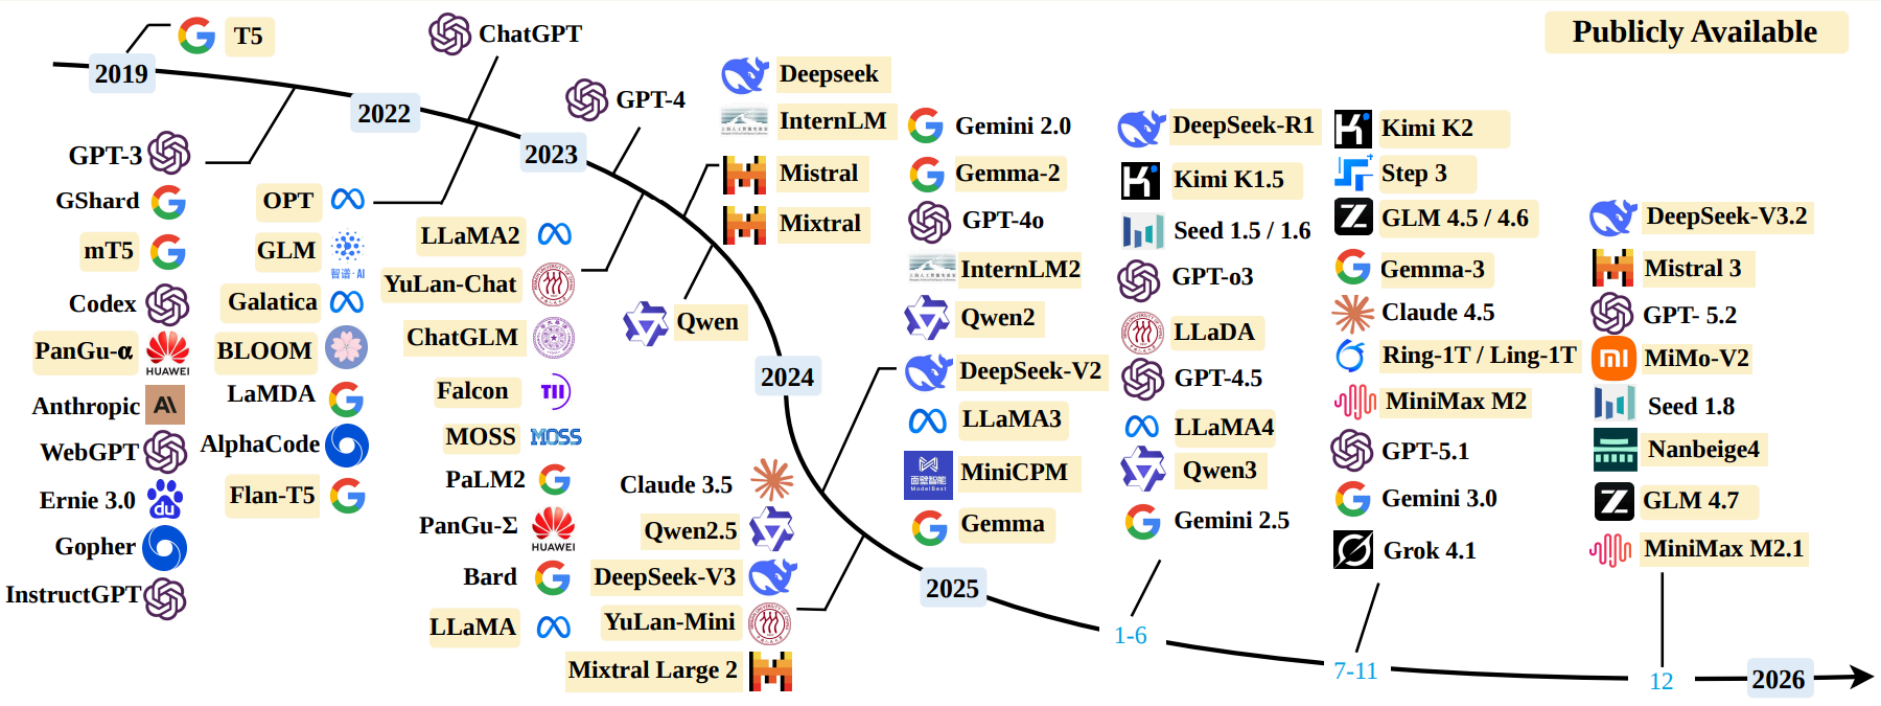

图 4: 近年来发布的代表性大语言模型时间线

核心法则之一：扩展定律 (Scaling Laws)

扩展定律 (Scaling Laws)揭示了大模型能力的底层逻辑：神经语言模型的任务性能（L为损失函数值，越小越好）与**模型规模**（N）、**数据规模**（D）以及**训练计算量**（C）之间呈现显著的幂律（Power-law）关系：

$$L(N) \propto N^{-\alpha} \qquad \text{(model scaling)}$$
$$L(D) \propto D^{-\beta} \qquad \text{(data scaling)}$$
$$L(C) \propto C^{-\gamma} \qquad \text{(compute scaling)}$$

- **KM Scaling Law (OpenAI)**：当计算预算增加时，应将更多预算优先分配给模型参数规模 。
- **Chinchilla Scaling Law (DeepMind)**：提出“计算最优（Compute-optimal）”法则，主张模型参数与数据规模应以同等比例进行扩展 。

商业与工程价值：可预测的扩展 (Predictable Scaling) 。在极度昂贵的大规模训练中，研究者可以通过训练较小的代理模型来可靠地估算超大模型的最终性能 。这一机制为算力资源的最优分配（如寻找最佳数据混合比例）及训练状态异常监控提供了科学指导。

核心法则之二：涌现能力 (Emergent Abilities)

什么是涌现能力？在小规模语言模型中尚未存在，而当模型参数规模跨越特定临界阈值时突然涌现的能力。其性能表现出远超随机水平的急剧跃升，类似于物理学中的“相变”（Phase Transition）现象。

三大典型涌现能力：

- **上下文学习 (In-context learning)**：无需任何参数训练或梯度更新，模型仅凭借自然语言指令与少量示例，即可直接理解任务并生成预期输出。
- **指令遵循 (Instruction following)**：经过多任务指令微调，模型能够精准理解并遵循人类用自然语言表述的、未经训练的全新任务指令。
- **分步推理 (Step-by-step reasoning)**：借助思维链提示策略引入中间推理步骤，使大模型能够成功攻克包含多个环节的复杂逻辑与数学应用难题。

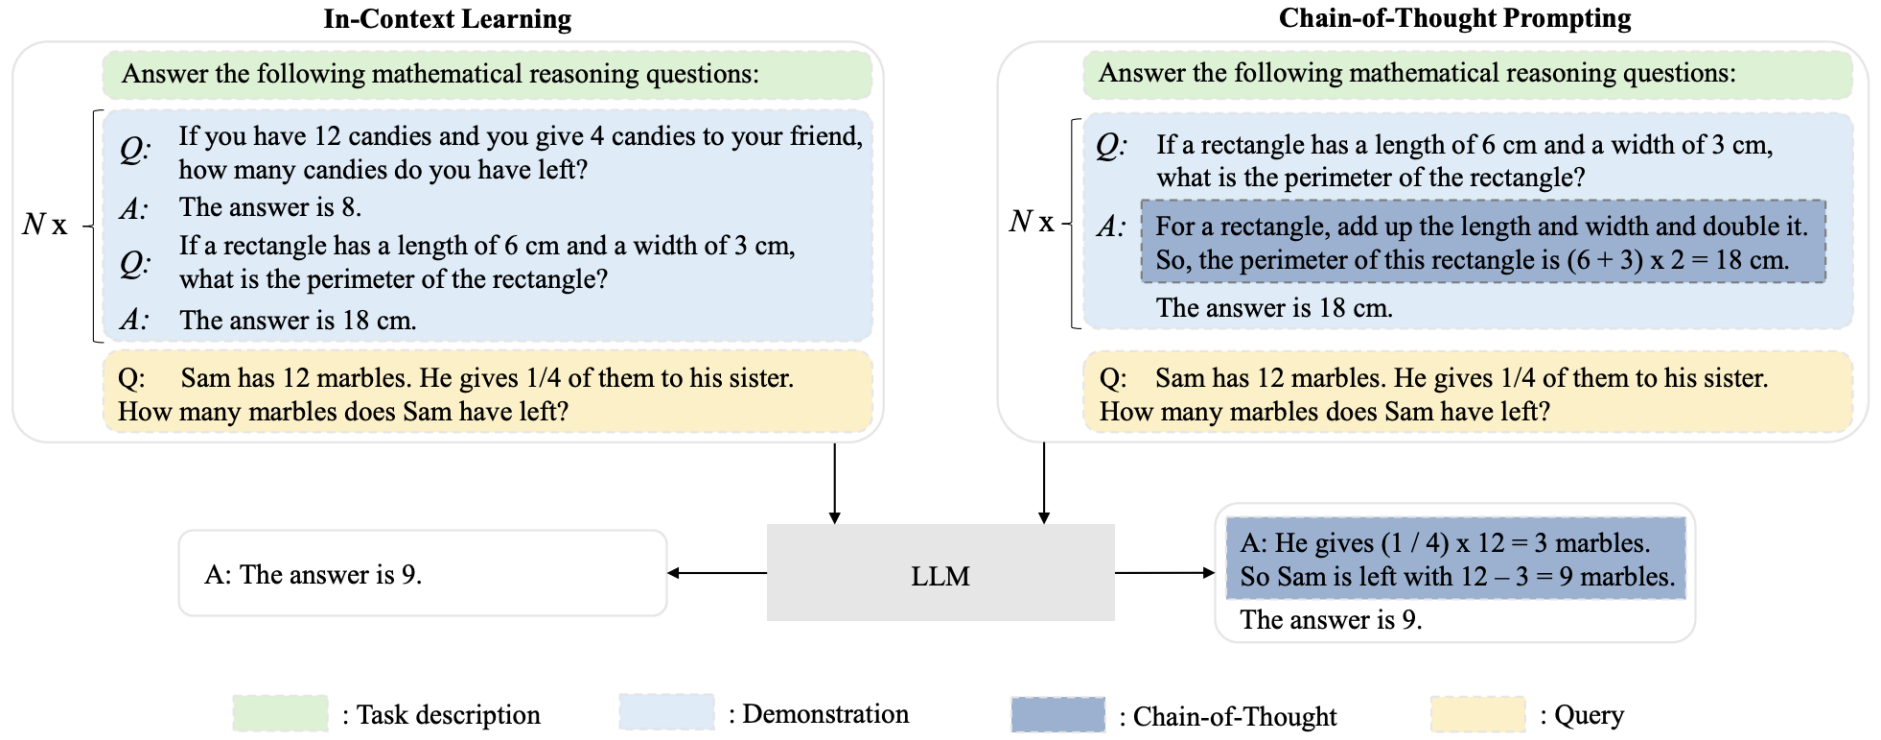

图 5: 上下文学习（ICL）与思维链（CoT）提示策略的对比图示

OpenAI 的技术演进路线图

核心理念：将广阔的世界知识压缩至仅包含解码器（Decoder-only）的 Transformer 模型中，通过准确“预测下一个词”来记忆并重构世界知识。

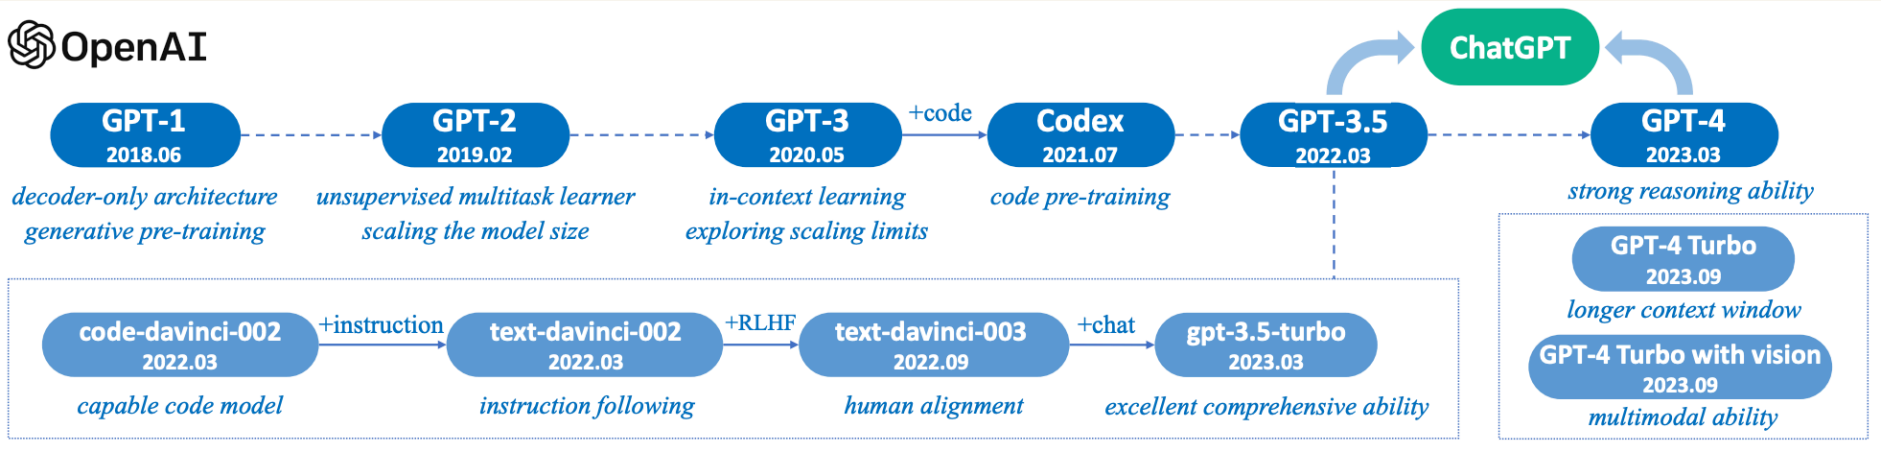

图 6: GPT系列模型技术演进的简要图示

- **GPT-1 & GPT-2：**确立了无监督生成式预训练的核心架构，并初步探索了无监督多任务学习范式。
- **GPT-3：**参数规模大幅扩展至1750亿（175B），正式引入上下文学习机制，通过量变引起质变，实现了模型通用任务求解能力的重大跃升。

能力增强与人类对齐 (Capacity Enhancement & Alignment)

在GPT-3奠定基础后，大模型通过两大核心技术路径实现了能力的进一步跃升与规范化：

- **代码训练 (Training on code data)**：引入 Codex 模型（基于大规模代码库微调），有效将代码严密的执行逻辑注入模型，极大增强了模型解决复杂编程与数学问题的逻辑推理能力。
- **人类价值观对齐 (Human alignment)**：推出 InstructGPT（ChatGPT的前身），确立了**基于人类反馈的强化学习（RLHF）**范式，确保模型生成的内容符合“有用、诚实、无害”（Helpful, Honest, Harmless）的人类期望。

GPT-4 及其后续演进：突破单一文本限制，支持多模态输入（如视觉信息接入），并大幅提升了复杂推理准确性与超长上下文的处理能力。

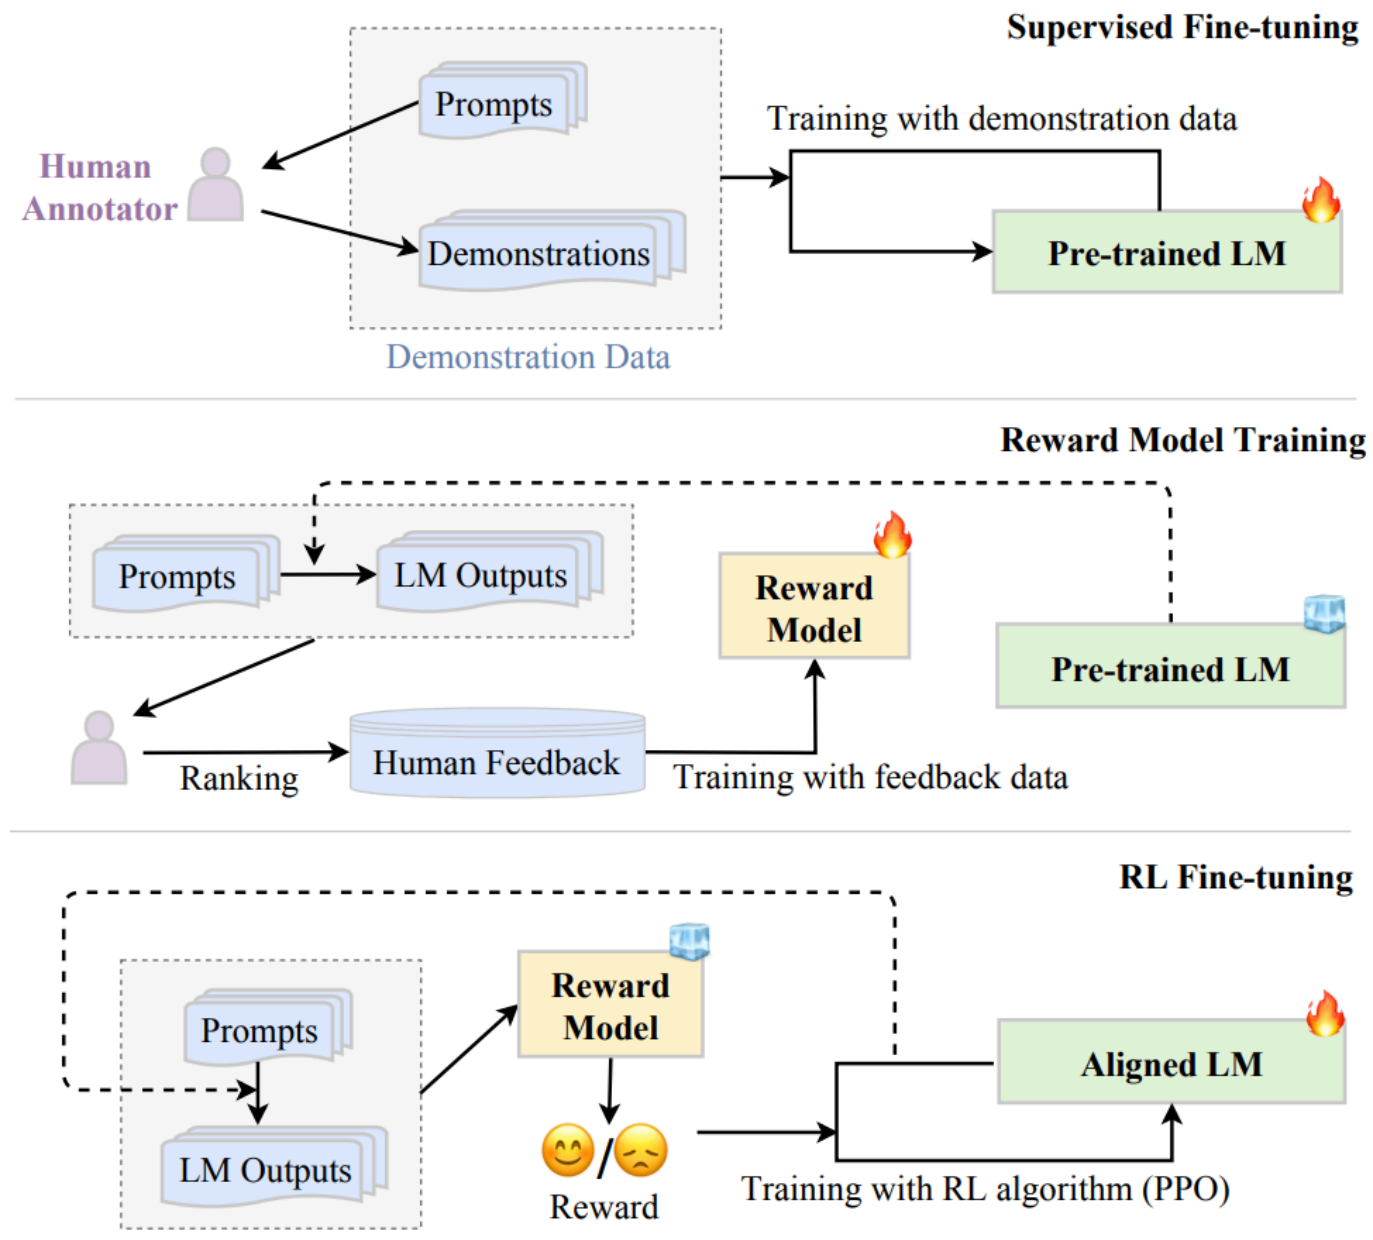

图 7: RLHF（基于人类反馈的强化学习）算法的工作流程

提示词工程 (Prompt Engineering) 的艺术

人类与大语言模型交互的主要范式：通过提示接口（Prompting Interface）运用自然语言激发模型潜能。构建高质量 Prompt 的四个核心要素：

- **任务描述 (Task description)**：清晰、明确的自然语言目标指令。
- **输入数据 (Input data)**：模型需要处理的具体目标文本或数据。
- **上下文信息 (Contextual information)**：相关的背景知识或参考资料。
- **提示风格 (Prompt style)**：特定引导前缀或角色扮演（如专家视角）。

商业应用示例：商业合同关键实体提取

Prompt设计: “你是一位资深的商业法务专家 (提示风格)。请阅读以下采购合同，提取其中的三个关键信息：*1.* 甲方名称；*2.* 乙方名称；*3.* 交易总金额 (任务描述)。合同内容如下：*[*插入合同原文*]* (输入数据)。”

释放大模型潜力的高级技巧

在不改变模型底层参数的前提下，引导大模型解决复杂的商业分析任务：

- **上下文学习 (In-context Learning, ICL)**：通过在提示词中提供少量高质量的任务示例（Few-shot demonstrations），帮助模型隐式地学习输入到输出的映射关系，在无需额外训练或梯度更新的情况下完成新任务。
- **思维链 (Chain-of-Thought, CoT)**：在提示词中加入如“Let's think step by step”等引导语，激发大模型生成串联输入与输出的“中间推理步骤”，从而有效突破复杂商业逻辑与数学计算的推理瓶颈。

走向自动化：LLM 智能体 (LLM-based Agent)

将大语言模型作为系统的“核心计算单元”（大脑），通过感知环境、自主决策并调用外部工具来完成开放域的复杂任务。**智能体的三大核心组件：**

- **记忆 (Memory)**：存储与检索环境感知信息，分为短期记忆（上下文窗口）与长期记忆（外部向量数据库）。
- **规划 (Planning)**：基于记忆信息进行任务分解，生成文本或代码形式的行动计划。
- **执行 (Execution)**：由内部模型自身或调用外部工具（如搜索引擎）落实具体行动。

商业应用示例：自动化金融投资分析智能体

场景：撰写一份专业的个股投资建议书。
协同流程：智能体首先自主调用外部金融API**获取最新股市行情（工具调用/执行）**；随后结合企业库**提取并分析历史财报数据（长短期记忆交互）**；最后进行逻辑推理，**自动拆解报告结构并输出投资建议（规划与执行）**。

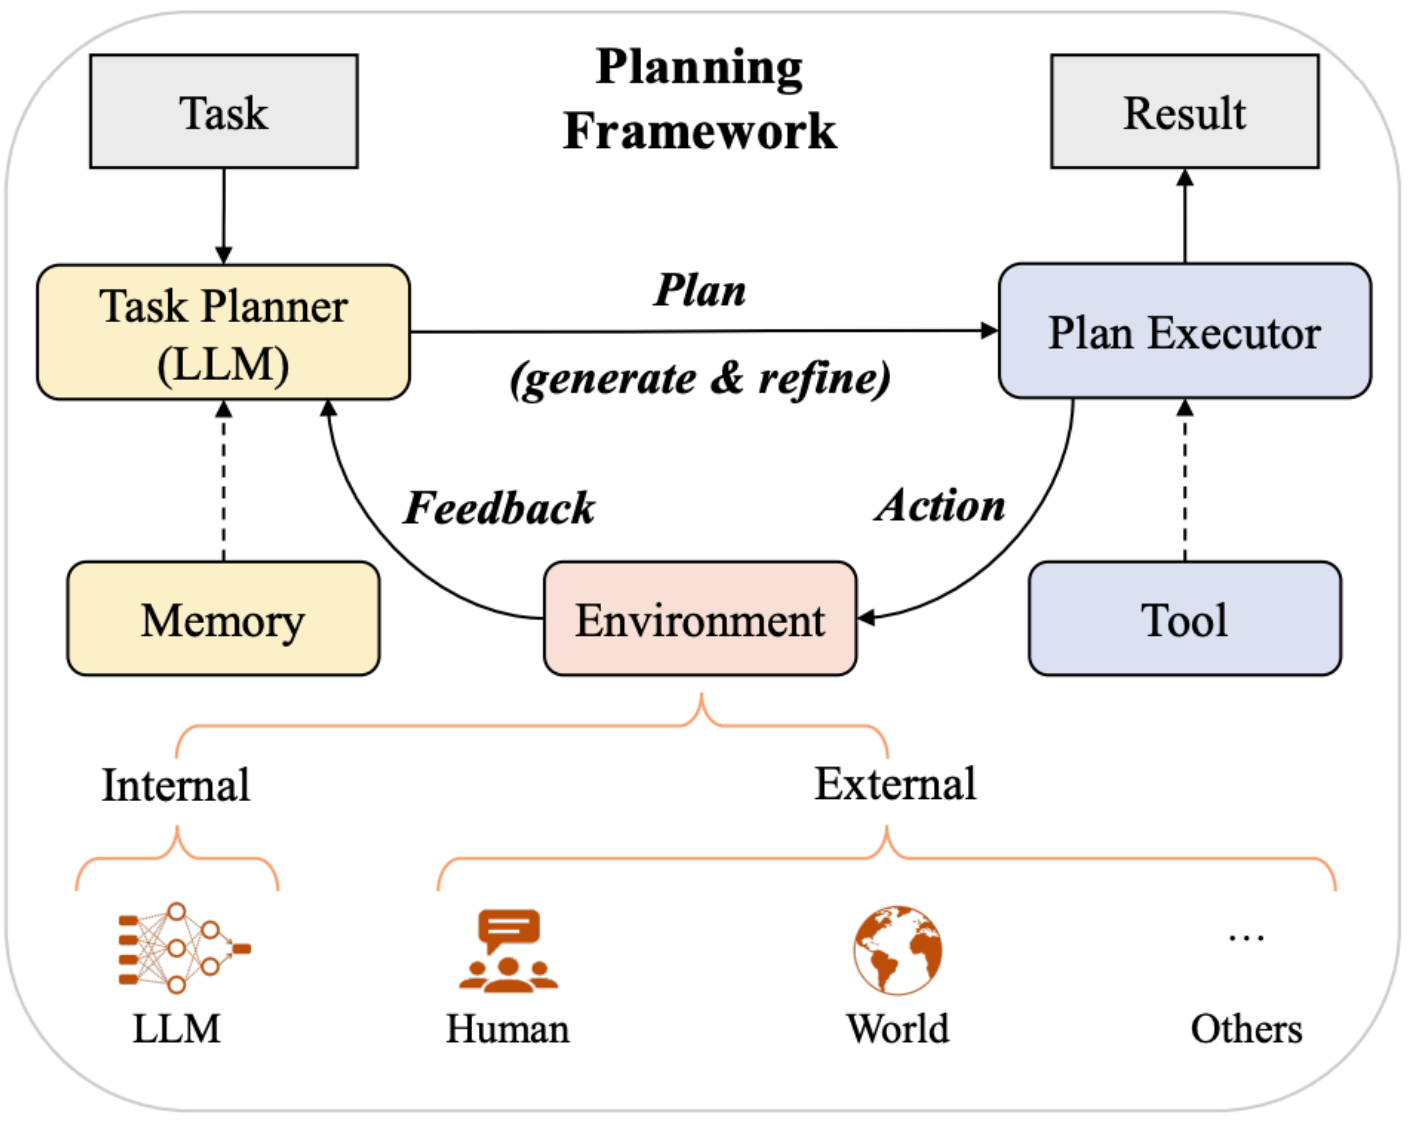

图 8: 基于大语言模型提示解决复杂任务的规划框架图示

低代码与无代码：智能体开发平台概览

为了降低大语言模型的应用门槛，业界涌现了多种智能体编排与工作流自动化平台，助力非技术背景的商业人才快速构建 AI 应用。

- **Coze**：主打零代码/低代码的对话式智能体构建。通过拖拽界面与丰富的预置插件，极大地简化了智能客服、业务咨询等助理应用的开发流程。
- **Dify**：开源的 AI 原生应用开发平台。以大语言模型编排和检索增强生成为核心，提供高质量的企业级知识库问答与私有化部署的管控能力。
- **n8n**：节点驱动的工作流自动化引擎。擅长将多系统的 API 数据流转与底层业务逻辑自动化，使大模型能作为关键节点无缝融入传统数字化流程。

平台能力对比与商业企业选型建议

不同的智能体平台在易用性、核心功能与部署方式上存在显著差异，企业需根据具体商业场景进行战略选型。

商业落地与系统选型建议：

- 对于侧重**C端交互与快速验证体验**的商科创业项目，首选 **Coze** 以实现最低成本的敏捷交付。
- 对于依赖**企业核心数据资产**并需要严谨业务推理的知识检索系统，**Dify** 是最佳的 AI 原生架构选择。
- 对于涉及**多部门系统集成、大规模数据流转与审批环节**的复杂后端操作，推荐采用 **n8n** 作为自动化神经中枢。

Computer-Use Agent：以 OpenClaw 为例

传统大模型主要在封闭对话框内生成文本，而 **Computer-Use Agent (计算机控制智能体)** 能够直接接管操作系统，模拟人类操作图形界面或终端环境。

- **技术突破**：模型不再仅仅“思考”，而是获得了“行动”的权限。可以自主读取文件、运行终端命令、浏览网页，甚至操作各类第三方桌面应用程序。
- **前沿代表：OpenClaw**：一款受广泛关注的开源本地自治 AI 智能体，可通过大模型直接管理计算任务。其支持跨渠道无缝交互（如 Telegram, WhatsApp 等），并具备自主安装分析工具与跨周期任务调度的能力。

自治化操作的商业潜能与安全博弈

引入 Computer-Use Agent 能够极大地释放业务生产力，但也使企业系统网络的安全边界变得更加脆弱和模糊。

- **高度自主与持久化机制：**以 OpenClaw 为例，其通过内置的“心跳机制（Heartbeat）”实现了主动规划而非被动响应。它能维持长期记忆，撰写每日运行日志，具备极高的商业自动化运营潜能。
- **安全风险激增：**由于智能体被赋予了本地系统的高级执行权限，面临严峻的**提示词注入（Prompt Injection）**与**数据越权外发（Data Exfiltration）**风险。攻击者可能通过污染外部网页等方式，操控智能体泄露企业机密。
- **企业级部署策略：**在真实商业环境中，必须遵循“最小权限原则”，将此类自治智能体部署于沙盒虚拟机或隔离网络中，在效率与数据资产安全之间取得平衡。

AI Coding Agent：开发者的超级结对伙伴

AI Coding Agent 标志着自动化编程从单一的“代码补全”走向了“全生命周期自动化”，为非计算机专业人士主导开发定制化商业应用提供了可能。

- **工作范式跃升**：现代编码智能体能够理解全局代码库架构，自主进行业务需求拆解、多文件代码修改、自动化测试、Bug 溯源验证以及 Git 分支提交，形成一个完整的 **ReAct (Reasoning and Acting)** 闭环。
- **核心技术协议**：模型上下文协议 (Model Context Protocol) 逐渐成为业界标准，使编码智能体能安全地从本地开发环境或外部协同工具（如Google Drive）中提取上下文，彻底打通了商业需求与技术研发的信息孤岛。

主流 AI Coding Agent 对比 (Claude Code vs. Gemini CLI)

业界头部科技公司正在激烈角逐下一代命令行级别的 AI 编程助手：

- **Claude Code (Anthropic)**：直接运行在开发者终端的智能体。能够自动执行测试、重构繁杂代码，并在定位底层 Bug 时展现出极强的长文本逻辑分析能力。
- **Gemini CLI (Google)**：开源的终端 AI 代理工具，无缝集成了 VS Code 环境。不仅内置了 grep 与底层文件操作等工具，还引入了“Yolo 模式”以赋予模型更高的执行自主权。

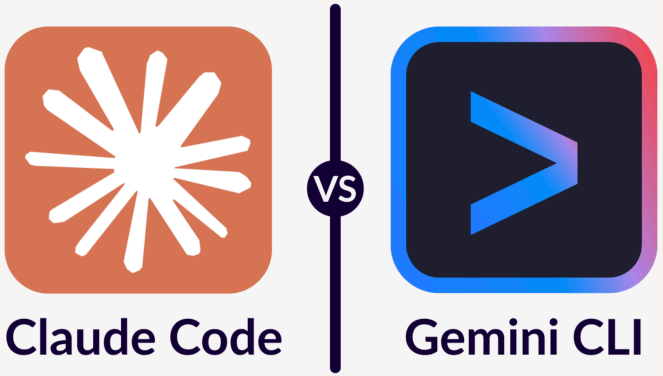

商业洞察： AI Coding Agent 的崛起意味着软件开发的生产力瓶颈被打破。未来商业数字人才的核心竞争力，将从传统的**基础代码编写能力**，加速向**商业需求定义、系统规划与产品架构设计能力**转移。

软件工程的新纪元：Vibe Coding (氛围编程)

核心转变：从“手写代码”到“表达商业意图”

Vibe Coding 是一种新兴的 AI 驱动开发范式。开发者只需使用自然语言描述业务逻辑与期望结果（即表达“意图”或“氛围”），而由 AI 智能体负责处理所有底层的代码语法与实现细节。

- **敏捷迭代闭环：**构建了以描述目标 → AI生成代码 → 运行观察 → 提供自然语言反馈 为核心的极速对话式开发流程。
- **研发角色重塑：**人类的注意力从底层的“实现细节”中完全解放，转变为全局的产品架构师与 AI 审查员。
- **商业赋能价值：**彻底打破了软件工程的技术壁垒。非技术背景的商科人才，如今也能依靠“纯意图驱动”以极低成本快速打造最小可行性产品（MVP），加速商业模式的验证。

LLM 赋能数字经济与商业分析

大语言模型正在深刻重塑数字经济的关键应用场景与商业分析范式：

- **金融领域 (Finance)**：以 BloombergGPT 等领域大模型为代表，广泛应用于金融情感分析、命名实体识别与复杂金融推理，显著提升金融数据处理与市场预测效能。基于多智能体的金融交易框架，如TradingAgents-CN。
- **推荐系统 (Recommender Systems)**：突破传统基于ID的协同过滤范式，利用大模型深入理解用户隐式意图并进行零样本排序。此外，LLM 还可作为真实用户的行为模拟器，用于洞察复杂的多智能体用户-物品交互演化。
- **信息检索 (Information Retrieval)**：深度赋能并增强现有搜索引擎的核心管道（如文本重排与查询重写），彻底重塑人类信息获取与交互的体系架构，主流的搜索引擎都嵌入了 LLM。各种大模型中的DeepResearch功能。

大模型的“阿喀琉斯之踵”

大语言模型在实际商业落地中仍面临显著的局限性与风险挑战：

- **幻觉问题**：模型容易生成与事实不符、产生内部冲突（内在幻觉）或无法被现有信息源验证（外在幻觉）的内容。
- **知识时效性**：大模型内部的参数化知识难以进行低成本的实时更新。应对时效性商业分析（如最新财报），通常需要结合检索增强生成（RAG）等技术引入外部最新知识源。
- **安全性与价值观对齐**：大模型可能产生有偏见、有害或误导性的表达。商业系统的部署必须严格遵循“有用、诚实、无害”的人类价值观对齐标准，以规避合规与伦理风险。

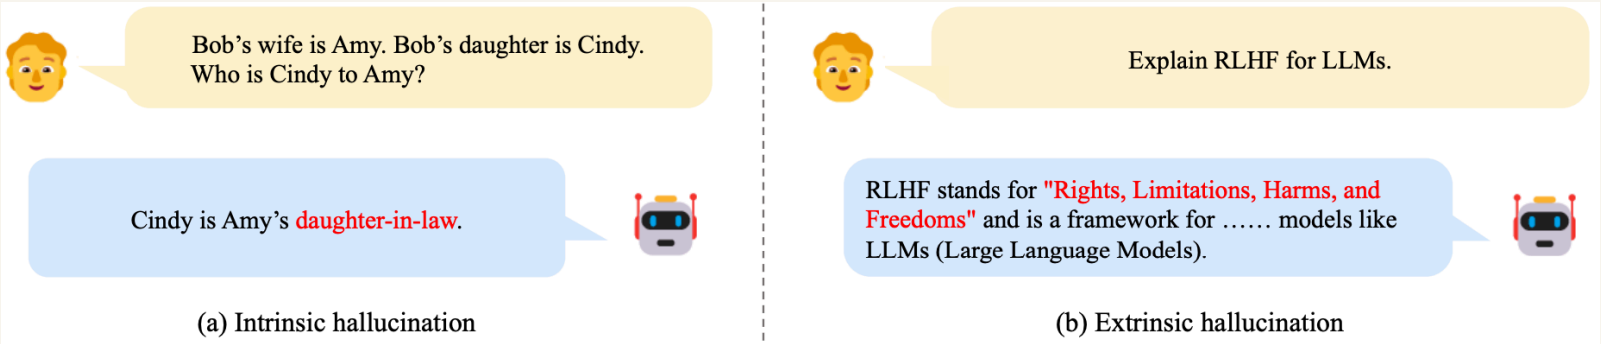

图 9: 公开大语言模型的内在幻觉与外在幻觉示例

1. **数据收集**：获取与研究主题相关的文本数据，来源包括网络爬虫、公开数据库、企业内部文档等。
2. **文本预处理**：对原始文本进行清洗和规范化处理，以提高后续分析的准确性和效率。主要步骤包括：
   - **去除非文本内容**：删除HTML标签、脚本、样式等非文本元素。例如，原始文本为：

     ```
     <div>公司业绩报告</div><script>alert('test');</script>
     ```

     预处理后应为：

     ```
     公司业绩报告
     ```

   - **中文分词**：由于中文文本中词语之间没有空格，需要进行分词处理，将句子拆分为独立的词语。例如，原始文本为："公司财务状况好。"预处理后应为："公司/财务/状况/好。"

- **词性标注**：在分词的基础上，为每个词语分配相应的词性标签，如名词、动词、形容词等。
- **去除停用词**：删除如“the”、“is”等对分析无实质意义的常见词汇。
- **拼写检查和更正**：识别并修正拼写错误，确保文本质量。
- **词形归一化**：将不同形式的词语还原为其基本形式，如将“running”还原为“run”。
- **大小写统一**：将所有文本统一为小写，避免因大小写差异导致的重复。

3. **特征提取与表示**：将处理后的文本转换为计算机可理解的结构化数据形式，如向量表示。常用方法包括：
   - **词袋模型（Bag of Words）**：忽略词序，将文本表示为词频向量。
   - **TF-IDF（Term Frequency-Inverse Document Frequency）**：衡量词语在文档中的重要性，降低常见词的权重。
   - **词嵌入（Word Embedding）**：如Word2Vec，将词语映射到低维连续向量空间，捕捉词语之间的语义关系。
4. **数据挖掘与分析**：应用统计和机器学习方法对特征化的文本数据进行分析，挖掘潜在模式和知识。常见任务包括：
   - **文本分类**：将文本分配到预定义的类别，如垃圾邮件检测。

- **聚类分析**：将相似的文本分组，发现潜在主题。
- **情感分析**：判断文本的主观情感倾向，如正面或负面评价。
- **主题模型**：如LDA（Latent Dirichlet Allocation），从大量文档中发现隐藏的主题结构。

5. **结果评估与可视化**：对分析结果进行评估，确保模型的有效性和可靠性，并通过可视化手段展示，便于理解和决策。

LLM提示词示例-文本预处理

你是一位资深的自然语言处理工程师，请对下面三引号中的文本进行分词和词性标注，以JSON格式返回结果：

"""
对我们许多人来说，工作、家庭和家人的综合需求意味着我们总是感觉时间不够用。数字技术也加剧了时间贫乏。永久连接延长了工作时间，也使我们难以摆脱朋友和家人的要求。
"""

1. **文本分类**：将文本数据分配到预定义的类别中。例如，在客户反馈处理中，可将评论分类为“正面”、“中性”或“负面”，以评估客户满意度。

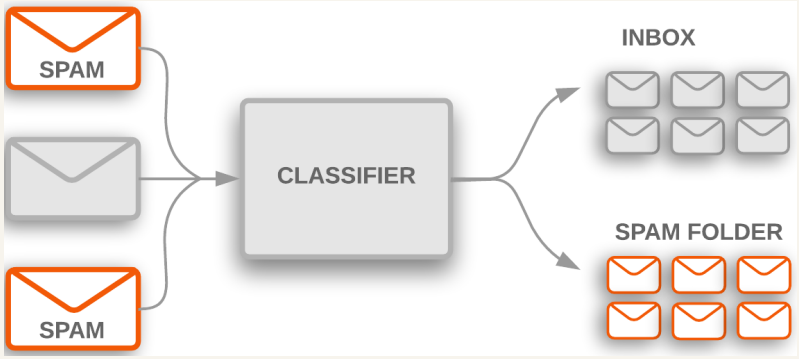

2. **文本聚类**：在没有预定义类别的情况下，将相似的文本自动分组。此方法可用于市场调研，识别消费者对产品的不同看法，发现潜在的市场细分。

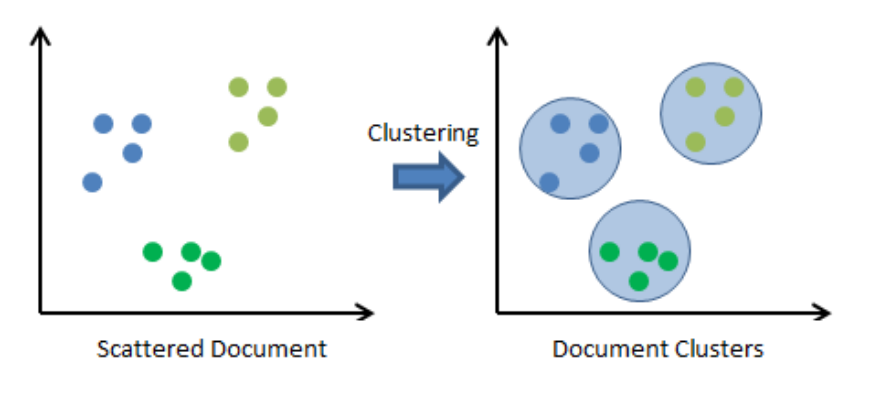

3. **情感分析**：检测和提取文本中的主观情感信息，判断其情感倾向。企业可利用情感分析了解社交媒体上对品牌的公众情绪，及时调整营销策略。

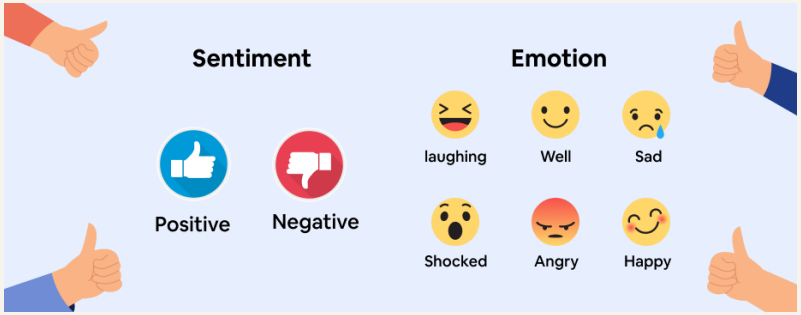

4. **主题模型**：从大量文档中发现隐藏的主题结构，如**隐含狄利克雷分布（Latent Dirichlet Allocation，LDA）**。这有助于企业了解市场趋势，制定相应的业务策略。

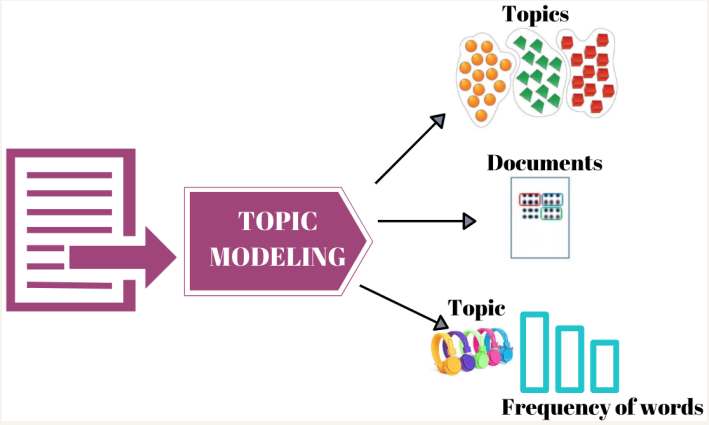

5. **信息抽取**：从文本中自动提取特定的结构化信息，如实体、关系和事件。例如，在财务报告中提取公司名称、财务指标等关键信息，便于后续分析。

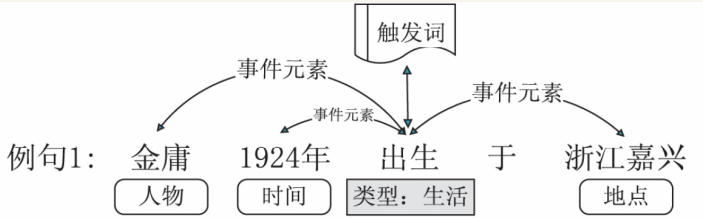

事件类型	生活（出生）	
事件触发词	出生	
事件元素	金庸	角色=人物
	1924 年	角色=时间
	浙江嘉兴	角色=地点

6. **自动摘要**：生成文本的简短摘要，保留关键信息。可帮助快速获取报告的核心内容，提高决策效率。

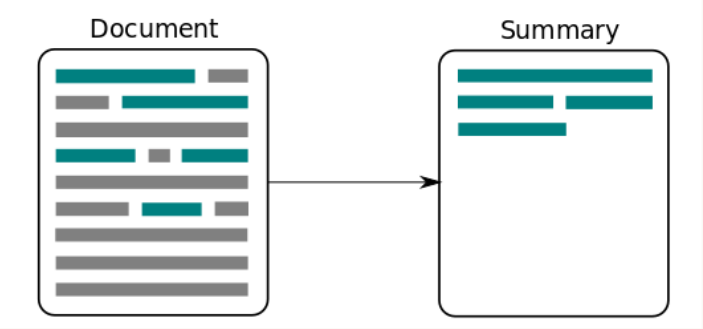

LLM提示词示例-信息抽取

你是一位资深的自然语言处理工程师，请对下面三引号中的文本进行**事件信息抽取**，以表格格式返回结果：

"""

马斯克(Elon Musk)麾下人工智能初创公司xAI推出最新版AI模型Grok 3，声称该模型在各种基准测试中均优于DeepSeek和OpenAI的模型。

"""

Kaggle注册

1. **安装Chrome插件**：离线安装插件Header Editor.crx (点我下载)；
2. **导入插件配置**:开启Header Editor插件,导入配置文件HE-GoogleRedirect.json (点我下载)；
3. **注册Kaggle**：在Chrome开启Header Editor插件，使用常用邮箱注册Kaggle (`https://www.kaggle.com/`)，如QQ邮箱；
4. **验证手机号**：在Kaggle的账户设置中 (settings)绑定、验证常用手机号；
5. **编写代码**：登录Kaggle，进入Code界面 (`https://www.kaggle.com/code`)，新建代码文件，在右侧边栏，打开联网功能(Internet on)，便于在代码文件中联网下载安装软件包，根据需求选择GPU加速 (ACCELERATOR)，编写示例代码；

Kaggle使用

```
# 联网安装自然语言处理工具包spaCy和中英文模型
! pip install -U pip setuptools wheel
! pip install -U spacy
! python -m spacy download zh_core_web_sm
! python -m spacy download en_core_web_sm

# 使用中文模型处理实例语句
import spacy

nlp = spacy.load("zh_core_web_sm")
text = "文本挖掘是1门非常有趣和有用的课程，2025年元气满满哒^_^。"
doc = nlp(text)
print(doc.text)
print("-"*20)
for token in doc:
# 词语，词性，是否是停用词
print(token.text, token.pos_, token.is_stop)
```

7. 课后实践

1. 熟悉Kaggle的基本用法，了解常用的shell命令 (文件操作，目录跳转等)；
2. 安装并使用阿里云开源的类OpenClaw产品-CoPaw；
3. 安装并使用美团光年之外团队开发的浏览器智能体Tabbit；
4. 使用CoPaw或者Tabbit完成一项你日常需要手工完成的任务，谈谈你对CoPaw或者Tabbit的使用感受；

THE END