

第五讲 - NLP基础算法：逻辑回归

张建章

阿里巴巴商学院
杭州师范大学

2026-03-01



- 1 判别模型
- 2 Sigmoid函数
- 3 二分类逻辑回归
- 4 多类别逻辑回归
- 5 逻辑回归模型的参数学习过程
- 6 交叉熵损失函数
- 7 梯度下降
- 8 正则化
- 9 多类别逻辑回归梯度计算
- 10 逻辑回归模型解释
- 11 课后练习

1. 生成模型与判别模型的对比

朴素贝叶斯是一种生成模型，它通过建模类别如何生成输入数据（即计算似然 $P(d|c)$ 与先验 $P(c)$ ），来推导后验概率 $P(c|d)$ ；逻辑回归则是一种判别模型，**直接学习输入与类别之间的映射**，即，直接估计 $P(c|d)$ 。

直观比喻说明：生成模型会尝试了解“狗长什么样”和“猫长什么样”，而判别模型只关心“如何区分狗和猫”。这种区别使得逻辑回归**能更直接地关注那些对区分不同类别最有用的特征**，而不必刻意去理解每个类别的完整分布。

2. 逻辑回归的特点

逻辑回归是一种用于**发现输入特征与某个特定结果之间联系的监督学习算法**，可以用于将观察实例划分为两个类别，也可以扩展为多类别情形，即，**多项逻辑回归 (softmax回归)**。

它不仅是社会科学和自然科学中极为重要的分析工具，也是NLP领域中**最常用的分类基线模型之一**。此外，逻辑回归与神经网络有密切关系，**神经网络可以看作是由多个逻辑回归分类器逐层堆叠而成的**。

3. 概率分类器的组成要素

构建一个概率分类器所需的四个核心组件 (以逻辑回归为例):

- ① **特征表示**: 将每个输入实例 $x^{(i)}$ 表示为一个特征向量, 例如 $[x_1, x_2, \dots, x_n]$;
 - ② **分类函数**: 一个通过计算 $p(y | x)$ 来产生估计类别 $\hat{y}$ 的函数, 如, 用于二分类的Sigmoid函数以及多分类中的Softmax函数;
 - ③ **目标函数**: 通常以损失函数形式定义, 用来衡量模型输出与真实标签之间的差异, 进而作为模型学习的优化目标, 如, 交叉熵损失函数;
 - ④ **优化算法**: 更新参数以最小化损失函数值的方法, 例如, 随机梯度下降。
- 训练与测试阶段**: 训练阶段通过优化目标函数 (最小化损失函数) 来学习分类函数中的参数, 而测试阶段则利用学到的参数对新的输入实例进行类别概率的计算, 并依据概率大小作出最终分类决策。

二元逻辑回归的核心思想：通过对输入特征进行线性加权求和得到一个实数得分 z ，再利用Sigmoid函数将 z 映射为一个介于0和1之间的数值，从而实现概率估计，并最终用于二元分类决策。Sigmoid函数是将线性模型输出转化为概率的关键步骤。

1. 二元逻辑回归分类的背景

对每个输入实例 x （通常以特征向量 $[x_1, x_2, \dots, x_n]$ 表示）进行二分类决策，输出 y 的取值为 1（表示正类）或 0（表示负类）。模型的目标是估计 $P(y = 1 | x)$ ，即输入实例 x 属于正类的概率。

2. 线性组合与得分（Logit）的计算

为了做出分类决策，模型首先为每个特征分配一个权重 w_i （权重可以为正也可以为负，反映了该特征对分类决策的正向或负向影响），并设有一个偏置项 b 。将所有特征与对应权重进行线性组合，再加上偏置项，得到一个实数值得分 z ，即

$$z = w \cdot x + b$$

这里的 z 称为logit，它反映了输入 x 属于正类的“证据总量”，但 z 本身可能取任意实数值，不能直接作为概率解释。

3. Sigmoid函数及其作用

为了将得分 z 映射到概率区间 $(0, 1)$ 内，逻辑回归采用了Sigmoid（或称Logistic）函数，其定义为

$$\sigma(z) = \frac{1}{1 + \exp(-z)}$$

Sigmoid函数具有以下3个重要性质：

- **区间映射**：它能将任意实数 z 映射到区间 $(0, 1)$ ，正好符合概率的定义；
- **非线性特性**：在 z 附近近似线性，而当 z 远离 0 时，迅速饱和于0或1，这有助于抑制极端得分的影响；
- **可微性**：Sigmoid函数是光滑且处处可导的，为后续的通过梯度下降优化参数提供了数学基础。




Figure 5.1 The sigmoid function $\sigma(z) = \frac{1}{1+e^{-z}}$ takes a real value and maps it to the range $(0, 1)$. It is nearly linear around 0 but outlier values get squashed toward 0 or 1.

概率映射：从线性得分到概率输出

1. 为什么需要 Sigmoid 函数？

线性组合 $z = w \cdot x + b$ 的取值范围是 $(-\infty, +\infty)$ 。但在商业场景中（如预测用户是否购买），我们需要一个严格在 $[0, 1]$ 之间的概率值。

2. Sigmoid 的“桥梁”作用

Sigmoid 函数 $\sigma(z)$ 完美充当了这座桥梁，将线性得分 z 转换为正类（如：购买/好评）的发生概率：

$$P(y = 1 \mid x) = \sigma(z) = \frac{1}{1 + \exp(-z)}$$

3. 中心对称性

正类概率是 $\sigma(z)$ ，基于 Sigmoid 函数的中心对称性（关于点 $(0, 0.5)$ ），有 $1 - \sigma(z) = \sigma(-z)$ 。因此，负类的概率恰好就是对得分取负号后的 Sigmoid 值：

$$P(y = 0 \mid x) = 1 - \sigma(z) = \sigma(-z)$$

Logit到底是什么？

1. 商业中的“几率”（Odds）

在商业博弈中我们常看“几率”。如果事件发生概率为 p ，不发生概率为 $1 - p$ ，则**几率（Odds）**定义为：

$$\text{Odds} = \frac{p}{1 - p}$$

（例如：如果转化率 $p = 0.8$ ，则几率为 $0.8/0.2 = 4$ ，即“赢面是 4 比 1”）

2. 对数几率（Log-Odds / Logit）

对几率取自然对数，就得到了 **Logit 函数**：

$$\text{logit}(p) = \ln \left(\frac{p}{1 - p} \right)$$

3. 逻辑回归的终极直觉

Sigmoid 和 Logit 互为**逆函数**。将线性得分 z 称为 logit，意味着逻辑回归的本质是：**用输入特征的线性组合，去拟合“正类发生的对数几率”**。

$$z = \ln \left(\frac{p}{1 - p} \right)$$

利用逻辑回归模型进行分类决策

1. 利用Sigmoid函数进行概率估计

- 给定一个输入实例 x (通常表示为特征向量 $[x_1, x_2, \dots, x_n]$), 通过将输入与模型参数 (权重 w 和偏置 b) 线性组合得到得分 $z = w \cdot x + b$;
- 将得分 z 通过Sigmoid函数 $\sigma(z) = \frac{1}{1+\exp(-z)}$ 转化为一个介于 0 和 1 之间的数值, 从而估计正类概率 $P(y = 1 | x) = \sigma(w \cdot x + b)$;

2. 基于概率阈值分类决策

- 决策边界通常设定为 0.5: 如果 $P(y = 1 | x) > 0.5$ 则判定输入 x 属于正类 (例如正面情感), 否则判定为负类 (例如负面情感);
- 这种基于概率阈值的决策机制使得逻辑回归能够直接将连续的概率输出转换为离散类别标签。

情感分类应用示例

以电影评论情感分类为例，提取文档的多个特征（如正向词计数、负向词计数、否定词标识、代词计数、感叹号出现与否、文档长度等）构成特征向量。

Var	Definition	Value in Fig. 5.2
x_1	count(positive lexicon words $\in$ doc)	3
x_2	count(negative lexicon words $\in$ doc)	2
x_3	$\begin{cases} 1 & \text{if "no"} \in \text{doc} \\ 0 & \text{otherwise} \end{cases}$	1
x_4	count(1st and 2nd pronouns $\in$ doc)	3
x_5	$\begin{cases} 1 & \text{if "!"} \in \text{doc} \\ 0 & \text{otherwise} \end{cases}$	0
x_6	$\ln(\text{word count of doc})$	$\ln(66) = 4.19$




Figure 5.2 A sample mini test document showing the extracted features in the vector x .

假设已经通过训练学得权重向量 $[2.5, -5.0, -1.2, 0.5, 2.0, 0.7]$ 和偏置 $b = 0.1$ ，模型计算得到 $z = w \cdot x + b$ 后，通过Sigmoid函数转化为 $P(y = 1 | x) = 0.70$ ；因此，该电影评论被判定为正面情感。

$$\begin{aligned} P(y = 1 | x) &= \sigma(w \cdot x + b) \\ &= \sigma\left([2.5, -5.0, -1.2, 0.5, 2.0, 0.7] \cdot [3, 2, 1, 3, 0, 4.19] + 0.1\right) \\ &= \sigma(0.833) \\ &= 0.70 \\ P(y = 0 | x) &= 1 - \sigma(w \cdot x + b) \\ &= 0.30 \end{aligned}$$

特征值标准化 (standardization)

1. 为何需要对输入特征进行缩放

不同特征可能取值范围差异很大，这会导致在模型训练过程中，各特征对损失函数梯度的贡献不均，从而影响参数更新的效率和最终模型的收敛速度。当特征值处于可比较的数值范围内时，模型更容易平衡各个特征的影响，进而加快梯度下降的过程，提高学习效率。

2. z-score标准化方法

将每个特征的数据转化为均值为0、标准差为1的分布，使得各特征具有相似的尺度，具体操作是：

首先，计算特征 x_i 在所有 m 个样本中的均值 $\mu_i = \frac{1}{m} \sum_{j=1}^m x_i^{(j)}$ 和标准差 $\sigma_i = \sqrt{\frac{1}{m} \sum_{j=1}^m (x_i^{(j)} - \mu_i)^2}$ ；然后，用公式

$$x'_i = \frac{x_i - \mu_i}{\sigma_i}$$

将原始特征 x_i 转换为标准化后的特征 x'_i 。

3. 归一化 (normalization)方法

将特征值缩放到固定区间内（通常是0到1），这种方法有助于在模型中直接比较不同特征的数值。归一化操作的公式为：

$$x'_i = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)}$$

其中， $\min(x_i)$ 和 $\max(x_i)$ 分别表示特征 x_i 在数据集中出现的最小值和最大值。

4. 其他任务与特征设计

- 除了情感分类，逻辑回归还可以应用于其他文本分类任务（如句末标点的歧义消解等），在这些任务中，任何能够反映输入信息的属性都可作为特征；

- 特征既可以由人工设计，也可以通过表示学习自动获得；此外，还可以考虑特征之间的交互作用，以提高分类性能。

5. 批量处理与向量化实现

为了提高计算效率，逻辑回归通常采用**矩阵运算**对多个测试实例进行并行处理。将所有测试实例的特征向量构成一个矩阵 X （每行为一个实例），利用**矩阵乘法** $Xw + b$ 计算**所有实例的得分**，再对每个得分应用Sigmoid函数，快速获得所有实例的预测概率。这种向量化实现充分利用了现代计算硬件的**并行处理能力**，显著**加快了模型的预测速度**。

6. 分类器选择的讨论

- 相较于生成模型（如朴素贝叶斯），逻辑回归作为判别模型能**更直接地关注对类别判定有帮助的特征**，尤其在处理多个相关特征时更稳健。
- 朴素贝叶斯在某些小规模数据或短文本任务上可能表现不错，**在大规模数据或长文本中**，**逻辑回归通常**能提供更精确的概率估计和**更好的分类性能**。

1. 多类别问题背景与模型表述

- 当分类任务中类别数大于2时（例如新闻多分类），传统的二分类逻辑回归**不足以直接处理**，此时可采用多类别（多项式）逻辑回归模型。
- 在多类别逻辑回归中，每个输入实例 x **被映射到一个长度为 K 的输出向量**，其中 K 表示类别数。对于正确类别 c ，将其输出设为1，而其他类别均为0，这种表示方式称为 one-hot 编码。

2. Softmax函数的引入

- 多类别逻辑回归使用softmax函数来将模型输出（得分向量）转化为概率分布。**softmax函数是sigmoid函数的推广**，能够接受一个 K 维的任意实数向量 $z = [z_1, z_2, \dots, z_K]$ ，并将其映射到一个所有元素非负、总和为1的概率向量：

$$\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_{j=1}^K \exp(z_j)} \quad (1 \leq i \leq K)$$

这一公式确保了当某个 z_i 显著大于其他分量时，其对应的概率接近1，而其他分量的概率则接近0。

3. softmax函数在逻辑回归中的应用

- 在多项逻辑回归中，对于每个类别 k ，模型为输入 x 分别学习一个权重向量 w_k 以及偏置 b_k 。对于每个类别，其得分为 $w_k \cdot x + b_k$ ；
- 利用softmax函数，类别 k 的预测概率被计算为：

$$p(y_k = 1 \mid x) = \frac{\exp(w_k \cdot x + b_k)}{\sum_{j=1}^K \exp(w_j \cdot x + b_j)}$$

为了充分利用现代硬件设备的向量处理能力，多个类别对应的权重向量 $\{w_1, w_2, \dots, w_K\}$ 被组合成一个权重矩阵 W （其每一行对应一个 w_k ），偏置项则构成一个向量 b 。于是，所有类别的预测概率可以通过一条矩阵运算表达为：

$$\hat{y} = \text{softmax}(Wx + b)$$

上式实现了对所有 K 个类别概率的并行计算。

4. 多类别逻辑回归




Figure 5.3 Binary versus multinomial logistic regression. Binary logistic regression uses a single weight vector $\mathbf{w}$, and has a scalar output $\hat{y}$. In multinomial logistic regression we have K separate weight vectors corresponding to the K classes, all packed into a single weight matrix $\mathbf{W}$, and a vector output $\hat{\mathbf{y}}$. We omit the biases from both figures for clarity.

4. 多元逻辑回归模型的直观解释

- 将 W 的每一行 w_k 看作是类别 k 的原型或模板。输入向量与 w_k 的点积衡量了输入与类别 k 的相似度，因而逻辑回归实际上是在寻找与每个类别原型最相似的输入实例；
- 多项逻辑回归中，每个特征在不同类别下可以拥有不同的权重，这使得同一特征能够为不同类别提供正向或负向的证据，从而更细粒度地区分各类别。

参数学习的过程：利用交叉熵损失函数作为目标指标，将逻辑回归参数学习问题转化为一个凸优化问题，并通过梯度下降算法不断更新参数 w 和 b ，使模型在训练数据上的预测概率尽可能接近真实标签，从而实现有效的分类。

1. 参数学习目标

逻辑回归是一种监督学习方法，每个训练样本 $(x^{(i)}, y^{(i)})$ 已经带有正确标签 $y^{(i)}$ （对于二元分类， y 为0或1）。模型根据输入 x 通过计算 $z = w \cdot x + b$ 并应用 Sigmoid 函数，输出预测概率 $\hat{y} = \sigma(w \cdot x + b)$ ，学习目标就是使得 $\hat{y}$ 尽可能接近真实标签 y 。

2. 损失函数的引入

为了衡量模型输出 $\hat{y}$ 与真实标签 y 之间的差距，引入损失函数（cost function）。逻辑回归采用了交叉熵损失函数，对于单个样本，其形式为：

$$L_{CE}(\hat{y}, y) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

该损失函数的设计鼓励模型为正确标签赋予高概率，而对错误标签赋予低概率。

3. 优化问题的形式化

逻辑回归模型的学习问题可以形式化为一个凸优化问题，其目标是找到参数 $\theta = \{w, b\}$ 使得所有训练样本上的平均交叉熵损失最小：

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{m} \sum_{i=1}^m L_{CE}(f(x^{(i)}; \theta), y^{(i)})$$

由于交叉熵损失函数在逻辑回归中是凸的，这意味着不存在局部最小值，任何初始点通过适当的梯度下降都能达到全局最优解。

4. 梯度下降法及其变种

为了最小化损失函数，通常使用梯度下降算法，利用损失函数关于参数的梯度（即偏导数）来更新参数：

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L_{CE}(f(x^{(i)}; \theta), y^{(i)})$$

其中 η (eta) 是学习率，决定了每次更新的步长大小。

实践中，为了提高计算效率，经常使用随机梯度下降算法，即每次只利用单个或一小批训练样本来近似计算梯度，从而实现在线式参数更新，这在大规模数据训练中尤为常用。

1. 学习目标与参数定义

逻辑回归的学习 (训练) 目标就是使得 $\hat{y}$ 尽可能接近真实标签 y , 即, 对于任一观测 x , 分类器的输出 $\hat{y} = \sigma(w \cdot x + b)$ (取值为0-1之间的概率值) 与正确输出 y (取值为0或1) 之间的差距尽可能小:

$$L(\hat{y}, y) = \text{预测值与真实值之间的差异}$$

参数为Sigmoid函数中的 w 和 b 。

2. 用损失函数表示学习目标

- 直觉出发: 为了实现学习目标, 我们希望模型对真实标签极其自信, 即, 选择最优的参数 w 和 b , 使得训练样本中真实标签 y 发生的概率被最大化。
- 统计学术语: 这种“最大化真实标签概率”的方法, 在统计学中被称为(条件)最大似然估计, 用似然值表示学习目标。
- 加负号变“损失”: 机器学习优化器习惯“求最小值”而非最大值。因此, 给似然值加上负号, 得到损失值: “最大化似然”等价于“最小化损失”。

交叉熵损失函数推导

1. 概率模型的构建（似然值）

针对单个观测 x ，目标是学习出一组权重，最大化模型对单个观测 x 生成正确标签的概率 $p(y | x)$ ，

$$p(y | x) = \hat{y}^y (1 - \hat{y})^{1-y}$$

当 $y = 1$ 时， $p(y | x) = \hat{y}$ ；当 $y = 0$ 时， $p(y | x) = 1 - \hat{y}$ 。

2. 对数似然的计算

为了使数学处理更简洁，同时将乘法转换为加法，对概率 $p(y | x)$ 取自然对数，得到对数似然：

$$\log p(y | x) = y \log \hat{y} + (1 - y) \log(1 - \hat{y}),$$

对数函数保留了最大化概率的性质，最大化概率 $p(y | x)$ 等价于最大化其对数。

3. 构造损失函数：负对数似然

在机器学习中，通常是通过最小化一个损失函数来训练模型。为此，将对数似然取负，构造出损失函数：

$$L_{CE}(\hat{y}, y) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

上式称为交叉熵损失函数。损失值越低，说明模型输出的概率分布与真实标签分布越接近。

4. 将模型参数与损失函数联系起来

在逻辑回归中，模型通过计算线性组合 $w \cdot x + b$ 并将其传入Sigmoid函数得到预测概率 $\hat{y} = \sigma(w \cdot x + b)$ 。将这一结果代入交叉熵损失函数，得到：


$$L_{CE}(\hat{y}, y) = -[y \log \sigma(w \cdot x + b) + (1 - y) \log(1 - \sigma(w \cdot x + b))]$$

通过调整参数 w 和 b ，最小化这个损失函数，使得对于每个训练样本，**预测出的标签 $\hat{y}$ 尽可能接近真实标签 y** 。

5. 交叉熵损失的意义

- 对数似然衡量模型输出与真实分布之间的“相似度”，加上负号之后，交叉熵损失函数衡量了模型输出与真实分布之间的“距离”；

- 交叉熵损失函数 ($-\log(\hat{y})$ 或者 $-\log(1 - \hat{y})$) 具有较好的数学性质，当预测概率接近真实标签（即为1或0）时，损失趋近于0；当预测概率与真实标签相差较大时，损失会**迅速增大** (如下图所示，(0,1)对应的那段曲线)。这一特性促使模型在训练过程中不断提升对正确标签的置信度，从而提高分类性能。



1. 目标与背景

- 在逻辑回归中，目标是通过调整参数 $\theta = \{w, b\}$ 使得模型对训练数据的预测概率 $\hat{y} = \sigma(w \cdot x + b)$ 尽可能接近真实标签 y ;
- 损失函数（交叉熵损失）刻画了模型输出与真实标签之间的差距，而梯度下降法则用于在参数空间中寻找使得平均损失最小的参数集，即：

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{m} \sum_{i=1}^m L_{CE}(f(x^{(i)}; \theta), y^{(i)}).$$

其中， m 为测试集中的样本数量。

逻辑回归的交叉熵损失函数 $L_{CE}(\theta)$ 是凸函数（在函数图像上任意两点连线都不会低于函数图像本身），凸函数最多只有一个全局最小值，也就是说不存在多个局部最小值使得优化过程陷入困境。

因此，从任意初始点出发（开始训练时，为参数 θ 分配随机值，随机初始化）使用梯度下降法都能保证找到全局最小值。多层神经网络（深度学习模型）的损失函数通常是非凸的，具有多个局部最小值。在这种情况下，梯度下降可能会在某个局部最小值停滞，无法达到全局最优解，这也是深度学习模型训练中常见的挑战之一。

2. 梯度下降的基本原理

- **梯度的概念**：多变量函数在某一点的梯度是所有偏导数组成的向量，指向该函数**上升最快的方向**，为了使损失函数值下降，需要**向反方向更新参数**，即向梯度的相反方向移动。

- **直观解释**：类似于在峡谷中寻找下坡路径，梯度给出了上升最快的方向，因此我们选择沿着其反方向更新参数，从而快速降低损失。

- **更新规则**：考虑一个由参数 θ （如权重 w 和偏置 b ）构成的损失函数 L ，为了使损失函数下降，梯度下降法按照下面的规则更新参数：

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(f(x; \theta), y)$$

其中 η 是学习率，控制每次更新的步长大小。**逻辑回归交叉熵损失函数对单个权重 w_j 的偏导数为**：

$$\frac{\partial L_{CE}(\hat{y}, y)}{\partial w_j} = [\sigma(w \cdot x + b) - y] x_j = (\hat{y} - y) x_j$$

$$\frac{\partial L_{CE}(\hat{y}, y)}{\partial b} = [\sigma(w \cdot x + b) - y] 1 = (\hat{y} - y)$$


因此，预测误差与输入特征值的乘积决定了参数更新的方向。

单变量损失函数梯度下降示例

在单变量情况下，梯度可以理解为损失函数在该点的斜率，斜率的符号表示方向，绝对值表示Loss曲线沿这个方向的陡峭程度。

假如，参数 w 现在取值为 w^1 ，该点处的斜率为 -5 ，那么，接下来，参数 w 要往右侧移动（因为斜率为负数），靠近 $w^{\min}$ ，才能使Loss变小，假如步长 η 为0.1，那么， w^2 的取值就是 $w^2 = w^1 - 0.1 \times (-5)$ ，

思考一下：如果步长 η 太大或者太小，会怎么样。



多变量损失函数梯度下降示例

对于多维参数，每个参数都有对应的偏导数，其集合构成梯度向量。向量有方向和模长，梯度向量表示方向，模长表示 $Loss$ 曲面沿这个方向的陡峭程度。

假如，参数 (w, b) 现在的取值为下图中的红色箭头末端，红色箭头的顶端表示负梯度值，那么，接下来，参数 (w, b) 就要朝着红色箭头指向的方向移动了。




Figure 5.5 Visualization of the gradient vector at the red point in two dimensions w and b , showing a red arrow in the x - y plane pointing in the direction we will go to look for the minimum: the opposite direction of the gradient (recall that the gradient points in the direction of increase not decrease).

梯度下降的实际实现与优化策略

- **全量梯度下降**: $\frac{\partial L_{CE}(\hat{y}, y)}{\partial w_j} = [\sigma(w \cdot x + b) - y] x_j = (\hat{y} - y)x_j$ 是单个样本时的梯度计算公式, 对于包含 m 个样本的训练集合, 需要计算出 m 个 $\hat{y}$ (低效), 即:

$$\frac{\partial L_{CE}(\hat{y}, y)}{\partial w_j} = \frac{1}{m} \sum_{j=1}^m (\hat{y} - y)x_j$$

- **随机梯度下降**: 为了提高大规模数据训练的效率, 可采用随机梯度下降, 即每次仅利用一个随机训练样本来计算梯度, 并据此更新参数 (有噪声);

- **Mini-batch训练**: 为了平衡梯度估计的噪声和计算效率, 还可以采用 mini-batch 训练方法, 每次利用一组小批量样本进行参数更新, 从而获得更稳定的梯度估计并加速并行计算;

- **学习率调整**: 选择合适的学习率 η 至关重要, 过高可能导致参数更新过快而越过最优点, 过低则会使收敛速度缓慢。常见策略是初始采用较高学习率, 随后逐渐降低 (例如, 令学习率为训练迭代次数的函数)。(前面思考题的答案)

随机梯度下降 (Stochastic Gradient Descent)

随机梯度下降之所以被称为“随机”，是因为它在每一步迭代中随机选取单个样本进行计算，针对单样本进行参数优化，会导致参数非常不稳定的移动。

```

function STOCHASTIC GRADIENT DESCENT( $L()$ ,  $f()$ ,  $x$ ,  $y$ ) returns  $\theta$ 
  # where:  $L$  is the loss function
  #    $f$  is a function parameterized by  $\theta$ 
  #    $x$  is the set of training inputs  $x^{(1)}, x^{(2)}, \dots, x^{(m)}$ 
  #    $y$  is the set of training outputs (labels)  $y^{(1)}, y^{(2)}, \dots, y^{(m)}$ 

   $\theta \leftarrow 0$       # (or small random values)
  repeat til done  # see caption
    For each training tuple  $(x^{(i)}, y^{(i)})$  (in random order)
      1. Optional (for reporting):      # How are we doing on this tuple?
        Compute  $\hat{y}^{(i)} = f(x^{(i)}; \theta)$   # What is our estimated output  $\hat{y}$ ?
        Compute the loss  $L(\hat{y}^{(i)}, y^{(i)})$   # How far off is  $\hat{y}^{(i)}$  from the true output  $y^{(i)}$ ?
      2.  $g \leftarrow \nabla_{\theta} L(f(x^{(i)}; \theta), y^{(i)})$   # How should we move  $\theta$  to maximize loss?
      3.  $\theta \leftarrow \theta - \eta g$   # Go the other way instead
  return  $\theta$ 
  
```

Figure 5.6 The stochastic gradient descent algorithm. Step 1 (computing the loss) is used mainly to report how well we are doing on the current tuple; we don't need to compute the loss in order to compute the gradient. The algorithm can terminate when it converges (when the gradient norm $< \epsilon$), or when progress halts (for example when the loss starts going up on a held-out set). Weights are initialized to 0 for logistic regression, but to small random values for neural networks, as we'll see in Chapter 7.

小批量训练 (Mini-batch training)

1. 背景与动机

- 随机梯度下降 (SGD) 的问题：随机梯度下降每次仅选取单个训练样本来计算梯度并更新参数，这种“在线”更新方法虽然简单，但由于每次仅依赖单个样本的信息，导致参数更新过程可能“颠簸”较大，梯度估计不稳定。

- 全量梯度下降的局限：与之相对，全批量梯度下降利用整个训练集计算梯度，能获得准确的梯度方向，但其计算成本高昂（为更新一次梯度要计算一次全部测试样本的预测值），尤其在面对大规模数据集时效率较低。

2. 小批量训练的基本思想

- 折衷方案：为平衡梯度估计的准确性和计算效率，引入小批量训练的策略。该方法在每次迭代中不是只使用一个样本，也不是使用全部样本，而是采用一部分样本组成的小批量来计算梯度。

- 优点：① 通过同时处理多个样本，可以利用向量化操作大幅提升计算效率；② 小批量的梯度平均可以降低单个样本带来的噪声，使得梯度更新更加稳定，从而加速收敛。

3. 小批量损失函数

假设一个小批量包含 m 个样本，每个样本的输入与标签分别记作 $x^{(i)}$ 和 $y^{(i)}$ ，并假定这些样本相互独立。单个样本的交叉熵损失函数为

$$L_{\text{CE}}(\hat{y}, y) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

为了得到平均损失，定义小批量的损失函数为

$$\text{Cost}(\hat{y}, y) = \frac{1}{m} \sum_{i=1}^m L_{\text{CE}}(\hat{y}^{(i)}, y^{(i)})$$

4. 小批量梯度的计算

每个样本的梯度为 $(\hat{y} - y)x$ 。因此，小批量梯度就是各样本梯度的平均值：

$$\frac{\partial \text{Cost}(\hat{y}, y)}{\partial w_j} = \frac{1}{m} \sum_{i=1}^m \left[\sigma(w \cdot x^{(i)} + b) - y^{(i)} \right] x_j^{(i)}.$$

上式中的求和部分可以写为向量化表示，利用计算机硬件（GPU）进行矩阵运算，提高计算效率。

设 X 为形状为 $[m \times f]$ 的输入矩阵， f 为特征向量的维度， y 为形状为 $[m \times 1]$ 的标签向量，则全部参数 w 的梯度可写为：

$$\frac{\partial \text{Cost}(\hat{y}, y)}{\partial w} = \frac{1}{m} (\hat{y} - y)^T X = \frac{1}{m} (\sigma(Xw + b) - y)^T X.$$

小批量训练是介于随机梯度下降与全批量梯度下降之间的一种折衷方法。它既能利用多个样本的统计信息提高梯度估计的准确性和更新的稳定性，又能通过向量化操作降低计算成本，从而在大规模数据训练中兼顾效率与效果。

梯度下降计算实例

一、示例背景与初始设置

1. 样本选择与特征构造

选取一个简化示例：对单个训练样本，其特征向量仅包含两个分量：

- $x_1 = 3$ ：表示该文档中正面情感词（例如“great”、“awesome”等）的计数；

- $x_2 = 2$ ：表示该文档中负面情感词（例如“poor”、“terrible”等）的计数
该样本的真实标签为 $y = 1$ ，即表示正面情感。

2. 初始参数设置

模型参数包括权重向量和偏置项。初始权重和偏置均设为0：

$$w_1 = 0, \quad w_2 = 0, \quad b = 0$$

同时，初始学习率设为 $\eta = 0.1$ 。

二、单步梯度下降更新过程

1. 梯度计算公式

根据逻辑回归交叉熵损失的求导结果，对于单个样本，其梯度关于每个参数的偏导数表达式为：

$$\nabla_{w,b}L = \begin{bmatrix} \frac{\partial L_{CE}(\hat{y}, y)}{\partial w_1} \\ \frac{\partial L_{CE}(\hat{y}, y)}{\partial w_2} \\ \frac{\partial L_{CE}(\hat{y}, y)}{\partial b} \end{bmatrix} = \begin{bmatrix} (\sigma(w \cdot x + b) - y)x_1 \\ (\sigma(w \cdot x + b) - y)x_2 \\ (\sigma(w \cdot x + b) - y)1 \end{bmatrix}$$

其中， $\sigma(z)$ 表示 sigmoid 函数，其定义为 $\sigma(z) = \frac{1}{1+e^{-z}}$ 。

2. 在初始参数下计算梯度

由于初始参数均为0，则有：

$$z = w \cdot x + b = 0 \implies \sigma(0) = 0.5$$

因此，对于该样本 ($y = 1$):

- 对 w_1 的偏导数为：

$$\frac{\partial L_{\text{CE}}}{\partial w_1} = (\sigma(0) - 1)x_1 = (0.5 - 1) \times 3 = -1.5$$

- 对 w_2 的偏导数为：

$$\frac{\partial L_{\text{CE}}}{\partial w_2} = (\sigma(0) - 1)x_2 = (0.5 - 1) \times 2 = -1.0$$

- 对偏置 b 的偏导数为：

$$\frac{\partial L_{\text{CE}}}{\partial b} = \sigma(0) - 1 = 0.5 - 1 = -0.5$$

整体梯度向量为： $\nabla_{w,b} L = [-1.5, -1.0, -0.5]^T$ 。

3. 参数更新

根据梯度下降更新规则：

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_{\theta} L,$$

其中 θ 表示包含 w_1, w_2 以及 b 的参数向量。将初始参数 $\theta^{(0)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$ 和计算得到的梯度代入，利用学习率 $\eta = 0.1$ 得到：

$$\theta^{(1)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} - 0.1 \times \begin{bmatrix} -1.5 \\ -1.0 \\ -0.5 \end{bmatrix} = \begin{bmatrix} 0.15 \\ 0.1 \\ 0.05 \end{bmatrix}.$$

这表明在经过一次梯度下降更新后，参数从初始的全零状态调整为 $w_1 = 0.15$, $w_2 = 0.1$, $b = 0.05$ 。

三、结果解释

1. 参数更新的意义

更新后的参数表明模型对正面情感的证据进行了正向修正。具体来说：

- w_1 （与正面词计数相关）变为正值，增加了正类的概率；
- w_2 （与负面词计数相关）在本次更新中也变为正值，理想情况下如果遇到更多负例（其中 x_2 较大且 $y = 0$ ）， w_2 将会向负方向调整，从而更准确地区分正负情感。

2. 学习过程的动态性

本次更新仅基于单个正样本。整体模型训练过程中，梯度下降（或小批量训练）会不断利用多个样本的梯度信息，对所有参数进行迭代更新，使得模型最终能够以较低的平均损失拟合整个训练集。

商业案例：“星期二”的过拟合灾难

1. 场景：训练集中的“噪音”

- 任务：识别电商平台上的“虚假好评”。
- 偶然巧合：训练数据中碰巧有 5 条假评是“星期二”发布的。
- 过度学习：模型为了追求 100% 准确率，给“星期二”赋予了极大权重（例如 $w = 999$ ），认为这是核心特征。

2. 后果：泛化能力崩盘（失败的预测）

- 真实世界：一位正常买家在星期二发布了真诚的好评。
- 算法反应：由于“星期二”权重的统治地位，系统直接将其判定为“虚假”并误封账号。
- 结论：模型死记硬背了噪音，失去了泛化到新数据的能力。

3. 正则化的干预：做个“理性的导师”

- 逻辑：给高权重设置“罚款”（惩罚项）。
- 效果：模型发现给“星期二”分配大权重“太贵了”，被迫转向挖掘真正有意义的特征（如“返现”、“刷单”等），从而提高在未见数据上的表现。

正则化的背景与动机：防止“死记硬背”

现象：过拟合（Overfitting）的陷阱

- 在模型训练中，如果任由参数自由生长以达到“训练集完美拟合”，模型往往会“钻牛角尖”。
- 偶然相关性被放大：模型不仅捕捉到了真实的商业规律，还过分“死记硬背”了训练数据中的噪声。
- 后果：某些其实不重要的特征（如：评论刚好发布在“星期二”）因为碰巧区分了训练集，被赋予了极大的权重。导致模型在面对真实的新数据时（测试集）屡屡误判、表现不佳。

解决方案：引入正则化（Regularization）

- 核心动机：为了使模型能够更好地泛化（Generalize）到未见数据。
- 业务本质：给模型加上一个“成本约束”，通过惩罚项强行压制过大的权重。强迫模型忽略那些“偶然的噪音”，去寻找真正普遍适用的核心特征。

正则化项的基本构造

在优化目标（损失函数）中，在原有的最大化训练数据对数似然的基础上，额外加入一个正则化项，以惩罚权重过大的情况。(最大化)目标函数可以写为：

$$\hat{\theta} = \arg \max_{\theta} \left[\sum_{i=1}^m \log P(y^{(i)} | x^{(i)}) - \alpha R(\theta) \right]$$

其中：- $\theta = \{w, b\}$ 表示模型的全部参数， $R(\theta)$ 为正则化项， α 为正则化超参数，控制正则化项在整体目标中的权重。

正则化项的作用：如果模型完美拟合训练数据但需要使用极大权重，则正则化项会对这样的参数设置施加惩罚，从而使模型更倾向于选择那些虽然拟合效果稍逊但权重较小、泛化能力更好的参数组合。

常见的正则化方式（可视化）

L2正则化（岭回归）： L2正则化项利用参数向量的L2范数（即欧几里得距离的平方）：

$$R(\theta) = \|\theta\|_2^2 = \sum_{j=1}^n \theta_j^2$$

将L2正则化项加入到原始的目标函数中，得到正则化后的目标为：

$$\hat{\theta} = \arg \max_{\theta} \left[\sum_{i=1}^m \log P(y^{(i)} | x^{(i)}) - \alpha \sum_{j=1}^n \theta_j^2 \right]$$

特点： L2正则化倾向于使所有参数变得较小，即分散调整权重。其优点在于求导较简单（ $\frac{d}{d\theta} \theta^2 = 2\theta$ ），便于数值优化。L2正则化对应于假设参数服从均值为0的高斯（Gaussian）分布，即大多数参数应集中在0附近，且偏离0的概率随着距离的增加而迅速下降。

L1正则化 (Lasso回归): L1正则化项利用参数向量的L1范数 (即各参数绝对值之和):

$$R(\theta) = \|\theta\|_1 = \sum_{j=1}^n |\theta_j|$$

将L1正则化项加入到原始目标函数中, 目标函数为:

$$\hat{\theta} = \arg \max_{\theta} \left[\sum_{i=1}^m \log P(y^{(i)} | x^{(i)}) - \alpha \sum_{j=1}^n |\theta_j| \right]$$

特点: L1正则化倾向于使部分参数精确地变为0, 从而产生稀疏解, 这在特征选择上有明显优势。然而, 由于绝对值函数在0处不可微, 求导处理相对复杂。L1正则化对应于对参数施加拉普拉斯 (Laplace) 先验, 即认为参数分布服从尖峰且尾部较重的分布。

1. 多项式逻辑回归损失函数的构建

在二元逻辑回归中，标签 y 只有两种取值（例如 0 与 1），其损失函数为：

$$L_{CE}(\hat{y}, y) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})].$$

对于多类别问题（多项式逻辑回归），标签不再是单一的0或1，而是用一个one-hot向量表示：假设共有 K 个类别，则对于正确类别 c 有 $y_c = 1$ ，其它类别 $y_j = 0$ ($j \neq c$)。

损失函数表达：最大化模型对单个观测 x 生成正确标签的概率（似然）
 $p(y | x) = \prod_{j=1}^K \hat{y}_j^{y_j}$ ，多项式逻辑回归的交叉熵损失函数（负对数似然）为：

$$L_{CE}(\hat{y}, y) = - \sum_{j=1}^K y_j \log \hat{y}_j$$

由于只有正确类别 c 对应的 $y_c = 1$ ，其它 $y_j = 0$ ($j \neq c$)，故上述求和实际上只剩下正确类别一项，即

$$L_{CE}(\hat{y}, y) = -\log \hat{y}_c$$

输出概率计算：对于某个类别 k ，模型对于输入 x 的输出分数（也称为 logits）由线性函数计算得到：

$$z_k = w_k \cdot x + b_k,$$

然后利用 softmax 函数将这些分数转换为概率分布：

$$\hat{y}_k = p(y_k = 1|x) = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)}$$

因此，对于正确类别 c 的预测概率为

$$\hat{y}_c = \frac{\exp(w_c \cdot x + b_c)}{\sum_{j=1}^K \exp(w_j \cdot x + b_j)}$$

损失函数即为

$$L_{CE}(\hat{y}, y) = -\log \frac{\exp(w_c \cdot x + b_c)}{\sum_{j=1}^K \exp(w_j \cdot x + b_j)}$$

2. 梯度推导及参数更新

与二元逻辑回归类似，多项式逻辑回归的梯度推导目标在于计算损失函数关于各类别权重的偏导数，从而指导参数更新。对于某个类别 k 及对应权重 $w_{k,i}$ （即第 i 个输入特征对应于类别 k 的权重），梯度计算公式为：

$$\frac{\partial L_{CE}}{\partial w_{k,i}} = (\hat{y}_k - y_k) x_i$$

这里， y_k 是真实标签（只有正确类别取1，其它类别取0），而 $\hat{y}_k$ 则是由 softmax 得到的预测概率。

参数更新：基于上式，多项式逻辑回归采用梯度下降（或其变种，如随机梯度下降）更新参数。令学习率为 η ，则对于每个参数有：

$$w_{k,i}^{(t+1)} = w_{k,i}^{(t)} - \eta \frac{\partial L_{CE}}{\partial w_{k,i}},$$

即

$$w_{k,i}^{(t+1)} = w_{k,i}^{(t)} - \eta (\hat{y}_k - y_k) x_i$$

多类别逻辑回归梯度推导概要

① 从多类别的交叉熵损失函数

$$L_{CE} = - \sum_{j=1}^K y_j \log \hat{y}_j$$

对某个类别 k 的权重 $w_{k,i}$ 求偏导，其中， $\hat{y}_j = \frac{e^{z_j}}{\sum_{m=1}^K e^{z_m}}$ ， $z_m = \sum_i w_{m,i} x_i + b_m$ ，

② 利用链式法则，将求导过程拆分为三部分： L_{CE} 关于 $\hat{y}_j$ 的导数 ($-\frac{y_j}{\hat{y}_j}$)， $\hat{y}_j$ 关于 z_k 的导数 (因为 z_k 出现在每个 y_j 中，全微分)， z_k 关于的导数 $w_{k,i} (x_i)$ ；

③ 求 $\hat{y}_j$ 关于 z_k 的导数，利用softmax 函数的导数性质 (一个雅可比矩阵)；

④ 代回链式法则，最终得到梯度计算公式

$$\frac{\partial L_{CE}}{\partial w_{k,i}} = (\hat{y}_k - y_k) x_i$$

$$\frac{\partial L_{CE}}{\partial b_k} = (\hat{y}_k - y_k) 1$$

1. 解释性的重要性

- 在实际应用中，不仅需要知道模型的分类结果，更希望理解模型为何做出这种决策。也就是说，模型的“可解释性”要求能够揭示各个特征在决策过程中的作用和影响。这种解释能力对于构建透明、可信的模型至关重要，特别是在商业和决策支持等领域，用户需要知道模型判断背后的依据。

2. 逻辑回归的可解释性优势

逻辑回归模型通常采用人为设计的特征，这使得每个特征对应的权重具有明确的含义。通过观察特征对应的权重（如某特征对应的权重大小及其正负符号），可以直观判断该特征对分类决策的正向或负向影响以及影响的强度。例如，在情感分类中，某些词（如“好”、“喜欢”）可能具有正权重，而“差”、“糟糕”等词则具有负权重。

关于截距项 b ：当所有的特征输入 x 都为 0 时，综合得分 z 就等于 b ，它是“基准水平（Baseline）”。在排除了我们所有重点关注的特征之后，大盘数据天然存在的一种“自然倾向”。

3. 统计检验：给特征做“重要性体检”

为了进一步解释模型决策，逻辑回归常常结合统计检验方法（如似然比检验或Wald检验），**判断某一特征是否在统计上显著地影响分类结果**。这帮助我们揪出那些真正驱动模型决策的“关键少数”特征，让模型不再是一个黑盒。

4. 进阶应用：作为商业洞察的“显微镜”

逻辑回归不仅是分类器，更是探究**具体文本特征与分类标签之间独立关系**的严谨分析工具。

- **混杂偏误**：在情感分类中，若发现含“退货”的评论大多是差评，能否断定该词本身带有极强负面语义？未必。因为“商品品类”（如服装易因尺码退货且语气平和，家电退货多因故障且愤怒）作为**混杂因素**，同时影响着“退货率”和“情感极性”。
- **控制变量**：在多元逻辑回归中把可能的混杂因素（如，品类）显式地作为模型的特征值，例如，同时引入 X_1 (含退货)和 X_2 (品类)。参数 w_1 衡量的是在**保持 X_2 绝对不变**的条件下， X_1 对模型对数几率的独立边际贡献，即“退货”一词对于判定一条评论为差评的**净效应 (Net Effect)**。
- **原理解释**：模型在求梯度、更新 w_1 的时候（求偏导数时），假定其他所有变量（比如 w ）全都是常数，被冻结不动。

1. 复习下面微积分中的求导知识点，自行推导二分类逻辑回归和多分类逻辑回归中损失函数对模型参数的梯度。

- 对数函数的导数：

$$\frac{d}{dx} \ln(x) = \frac{1}{x}$$

- Sigmoid函数的导数：

$$\frac{d\sigma(z)}{dz} = \sigma(z)(1 - \sigma(z))$$

- 链式法则：对于复合函数 $f(x) = u(v(x))$ ，有

$$\frac{df}{dx} = \frac{du}{dv} \cdot \frac{dv}{dx}$$

- Softmax的导数涉及到一个雅可比矩阵（Jacobian Matrix），其中每个元素表示输出 y_i 对输入 z_j 的偏导数。经过求导计算，可以证明：

$$\frac{\partial y_i}{\partial z_j} = y_i(\delta_{ij} - y_j)$$

其中， δ_{ij} 是Kronecker δ 函数，当 $i = j$ 时 $\delta_{ij} = 1$ ，当 $i \neq j$ 时 $\delta_{ij} = 0$ 。

1. 二分类模型定义与损失函数

模型假设 (Sigmoid)

预测概率 $\hat{y}$ 通过 Sigmoid 函数计算:

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}$$

其中综合得分 $z = \sum_i w_i x_i + b$ 。

二元交叉熵损失函数 (BCE)

对于单个样本, 其预测概率与真实标签 $y \in \{0, 1\}$ 的误差定义为:

$$L_{BCE} = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

2. 链式法则：二分类梯度推导

利用链式法则，我们将对权重 w_i 的偏导拆解为三个连乘环节：

$$\frac{\partial L_{BCE}}{\partial w_i} = \underbrace{\frac{\partial L_{BCE}}{\partial \hat{y}}}_{\text{环节一}} \cdot \underbrace{\frac{\partial \hat{y}}{\partial z}}_{\text{环节二}} \cdot \underbrace{\frac{\partial z}{\partial w_i}}_{\text{环节三}}$$

分别求解这三个部分：

- 环节一： $\frac{\partial L_{BCE}}{\partial \hat{y}} = -\frac{y}{\hat{y}} + \frac{1-y}{1-\hat{y}} = \frac{\hat{y}-y}{\hat{y}(1-\hat{y})}$
- 环节二： $\frac{\partial \hat{y}}{\partial z} = \hat{y}(1-\hat{y})$ (Sigmoid 的优美求导性质)
- 环节三： $\frac{\partial z}{\partial w_i} = x_i$

相乘化简得到：

$$\frac{\partial L_{BCE}}{\partial w_i} = (\hat{y} - y) x_i$$

3. 多分类模型定义：严谨区分下标 j 与 k Softmax 概率输出（使用游标 j 遍历）

类别 j 的预测概率为：

$$\hat{y}_j = \frac{e^{z_j}}{\sum_{m=1}^K e^{z_m}}$$

多元交叉熵损失函数

使用游标 j 将所有类别的误差加总：

$$L_{CE} = - \sum_{j=1}^K y_j \log \hat{y}_j$$

我们的目标：锁定第 k 个特定类别，对它的参数 $w_{k,i}$ 求偏导。

4. 全微分：三环连乘链式法则

由于拨动 z_k 会通过 Softmax 的分母影响所有类别的概率 $\hat{y}_j$ ，必须对所有 j 受到的影响进行求和（全微分）：

$$\frac{\partial L_{CE}}{\partial w_{k,i}} = \left[\sum_{j=1}^K \underbrace{\left(\frac{\partial L_{CE}}{\partial \hat{y}_j} \right)}_{\text{环节一}} \cdot \underbrace{\left(\frac{\partial \hat{y}_j}{\partial z_k} \right)}_{\text{环节二}} \right] \cdot \underbrace{\left(\frac{\partial z_k}{\partial w_{k,i}} \right)}_{\text{环节三}}$$

其中：

- 环节一极其简单： $\frac{\partial L_{CE}}{\partial \hat{y}_j} = -\frac{y_j}{\hat{y}_j}$
- 环节三极其简单： $\frac{\partial z_k}{\partial w_{k,i}} = x_i$
- 核心难点在环节二： Softmax 的导数（雅可比矩阵）。

5. 核心难点: Softmax 的导数拆解

对于 $\frac{\partial \hat{y}_j}{\partial z_k}$, 我们需要分两种情况讨论:

- 情况 1: 当 $j = k$ 时 (目标类别本身)

$$\frac{\partial \hat{y}_k}{\partial z_k} = \hat{y}_k(1 - \hat{y}_k)$$

- 情况 2: 当 $j \neq k$ 时 (其他类别)

$$\frac{\partial \hat{y}_j}{\partial z_k} = -\hat{y}_j \hat{y}_k$$

上述两种情况的求导化简过程要利用商的求导公式, $(\frac{u}{v})' = \frac{u'v - uv'}{v^2}$ 和自然指数求导公式 $(e^x)' = e^x$ 。

汇总两种情况的计算结果, 可以得到一个雅可比矩阵, 其中的元素为:

$$\frac{\partial \hat{y}_j}{\partial z_k} = \hat{y}_j(\delta_{jk} - \hat{y}_k)$$

δ_{jk} 为克罗内克 δ 函数 (Kronecker Delta), 当 $j = k$ 时, $\delta_{jk} = 1$, 否则 $\delta_{jk} = 0$ 。

6. 代入消元

将上述导数代入全微分求和公式（定义 $\frac{\partial L_{CE}}{\partial z_k}$ ）：

$$\frac{\partial L_{CE}}{\partial z_k} = \underbrace{\left(-\frac{y_k}{\hat{y}_k}\right) \cdot [\hat{y}_k(1 - \hat{y}_k)]}_{\text{当 } j=k} + \underbrace{\sum_{j \neq k} \left(-\frac{y_j}{\hat{y}_j}\right) \cdot [-\hat{y}_j \hat{y}_k]}_{\text{当 } j \neq k}$$

化简并提取公因子：

$$\frac{\partial L_{CE}}{\partial z_k} = -y_k(1 - \hat{y}_k) + \sum_{j \neq k} y_j \hat{y}_k = -y_k + \hat{y}_k \left(y_k + \sum_{j \neq k} y_j \right)$$

One-hot 标签特性

因为真实标签 y 的总和永远为 1，即 $(y_k + \sum_{j \neq k} y_j) = 1$ 。所以：

$$\frac{\partial L_{CE}}{\partial z_k} = \hat{y}_k - y_k$$

7. 最终结论：梯度的统一之美

最后，将求得的误差项乘以特征输入 x_i ：

多分类逻辑回归梯度最终公式

权重参数的梯度：

$$\frac{\partial L_{CE}}{\partial w_{k,i}} = (\hat{y}_k - y_k) x_i$$

偏置参数的梯度：

$$\frac{\partial L_{CE}}{\partial b_k} = (\hat{y}_k - y_k) \cdot 1$$

商业直觉总结：无论是二分类还是多分类，梯度的本质永远是“**预测误差** $(\hat{y} - y) \times$ **输入特征** (x) ”。误差越大，参数纠错的步伐越猛！

THE END