


第八讲 - 循环神经网络

张建章

阿里巴巴商学院
杭州师范大学

2026-03-01



- 1 时序建模的必要性
- 2 循环神经网络
- 3 应用RNN构建语言模型
- 4 RNN在NLP任务中的应用
- 5 堆叠和双向RNN架构
- 6 长短期记忆网络（LSTM）
- 7 NLP中常见RNN架构总结
- 8 Encoder-Decoder模型
- 9 注意力 (Attention)机制
- 10 课后练习

1. 语言的时间性

语言天生具有时序性：无论是口语的声音信号，还是书面文本，都以序列的形式随时间展开。

2. 传统模型对时间性的处理及其局限

大多数此前学习的方法（如文本分类任务中的模型）都假设能够同时访问输入的所有部分，缺乏对时间顺序的内在建模。第7讲中介绍的前馈神经网络语言模型，也是通过固定大小的滑动窗口来捕捉上下文；每次只看定长的词序列，然后沿序列滑动，独立地预测下一个词。这种窗口方法虽然简单，但限制了模型对较长距离依赖的感知。

3. 循环神经网络（RNN）与长短期记忆（LSTM）

本讲介绍一种替代“滑动窗口”的深度学习架构——循环神经网络及其变体（如LSTM）。RNN通过在隐藏层引入循环连接，将前一时刻的隐状态作为当前输入的一部分，从而无需人为设定上下文长度，即可在理论上让模型记忆跨越任意距离的序列信息，并将其应用于语言建模、文本分类乃至序列标注（如词性标注、命名实体识别）等多种任务中。

2. 循环神经网络

1. 循环连接（Recurrence）

RNN是指网络中**存在环路（cycle）**的神经网络，某个单元的值直接或间接地依赖于其自身先前的输出作为输入。

2. Elman简单循环网络

简单循环网络（Simple RNN，本讲之后内容中使用RNN特指 Simple RNN）又称Elman Networks，其结构如下图所示：在输入层到隐藏层的前馈连接之外，隐藏层还接收来自上一步隐藏层的输出作为额外输入。




Figure 8.1 Simple recurrent neural network after [Elman \(1990\)](#). The hidden layer includes a recurrent connection as part of its input. That is, the activation value of the hidden layer depends on the current input as well as the activation value of the hidden layer from the previous time step.

3. 隐藏层记忆功能

上一时刻的隐藏层状态 h_{t-1} 相当于对序列先前信息的编码，不受固定窗口长度限制，可**理论上保留**从序列开头到当前的所有上下文。

RNN的前向推理 (Inference)

1. 逐步处理

序列按时序逐元素输入：在时刻 t 仅使用当前输入 x_t 与上一步隐藏状态 h_{t-1} 计算当前隐藏状态 h_t ，再计算输出 y_t 。

2. 计算公式

$$\begin{cases} h_t = g(Uh_{t-1} + Wx_t) \\ y_t = f(Vh_t) \end{cases}$$

其中， $W \in \mathbb{R}^{d_h \times d_{in}}$ 、 $U \in \mathbb{R}^{d_h \times d_h}$ 、 $V \in \mathbb{R}^{d_{out} \times d_h}$ 。输出通常经softmax归一化：

$$y_t = \text{softmax}(Vh_t)$$

3. 时间展开 (Unrolling)

将网络在各时刻复制并展开，可视为一个深层前馈网络，但**权重 W, U, V 在各时刻共享**，权重反向传播时需考虑跨时步的依赖。

2. 循环神经网络

前向推理的计算过程算法伪代码和示意图如下所示：

```
function FORWARDRNN( $\mathbf{x}$ ,  $\text{network}$ ) returns output sequence  $\mathbf{y}$ 
```

```
   $\mathbf{h}_0 \leftarrow 0$ 
```

```
  for  $i \leftarrow 1$  to LENGTH( $\mathbf{x}$ ) do
```

```
     $\mathbf{h}_i \leftarrow g(\mathbf{U}\mathbf{h}_{i-1} + \mathbf{W}\mathbf{x}_i)$ 
```

```
     $\mathbf{y}_i \leftarrow f(\mathbf{V}\mathbf{h}_i)$ 
```

```
  return  $\mathbf{y}$ 
```

Figure 8.3 Forward inference in a simple recurrent network. The matrices $\mathbf{U}$, $\mathbf{V}$ and $\mathbf{W}$ are shared across time, while new values for $\mathbf{h}$ and $\mathbf{y}$ are calculated with each time step.




Figure 8.2 Simple recurrent neural network illustrated as a feedforward network. The hidden layer $\mathbf{h}_{t-1}$ from the prior time step is multiplied by weight matrix $\mathbf{U}$ and then added to the feedforward component from the current time step.

RNN的训练——时序反向传播（BPTT）

1. 损失函数与误差传播

对每步输出 y_t 计算交叉熵损失，并对隐藏层在当前及后续时刻的影响（梯度）进行求和，得到针对 h_t 的总误差（梯度）。

2. 双向遍历

前向：逐时刻计算 h_t, y_t ，累积每一步的损失，并保存中间隐藏状态；

反向：从序列末端向前回传误差，计算各权重梯度。此即“通过时间的反向传播”（Backpropagation Through Time, BPTT）算法。

3. 梯度消失与网络深度

由于误差信号多次相乘，RNN易出现梯度消失（极其常见）或爆炸，导致难以学习长距离依赖。LSTM等门控结构的RNN变体可以缓解此类问题。

2. 循环神经网络

将RNN网络按时间步展开后，可视为一个深层前馈神经网络，如下图所示。




Figure 8.4 A simple recurrent neural network shown unrolled in time. Network layers are recalculated for each time step, while the weights U, V and W are shared across all time steps.

语言模型中的RNN框架

任务目标：语言模型根据先行上下文预测序列中下一个词的条件概率：


$$P(\text{fish} \mid \text{“Thanks for all the”})$$

链式法则：对整句概率建模时，将条件概率连乘：

$$P(w_{1:n}) = \prod_{i=1}^n P(w_i \mid w_{<i})$$

模型优势：与只依赖固定n-gram上下文的统计模型或前馈神经语言模型相比，RNN通过其隐状态 h_{t-1} **理论上**可保留从序列开始到当前的一切信息，无需任意窗口长度限制，**克服了**长距离依赖受限的问题。

使用前馈网络和RNN构建语言模型的差异



两种语言模型 (LM) 处理文本的架构简图 (以3个词的上下文为例): (a) 前馈神经网络: 输入到权重矩阵 W 的上下文长度是固定的; (b) RNN 语言模型: 利用隐藏状态 h_{t-1} 来概括历史上下文信息。

RNN语言模型前向推理

1. 输入表示：将当前词 x_t 编码为独热向量后，通过嵌入矩阵 E 映射到词向量

$$e_t = E x_t$$

2. 隐状态更新：结合前一步隐状态 h_{t-1} 与当前嵌入，计算新隐状态

$$h_t = g(U h_{t-1} + W e_t)$$

3. 输出层与概率：再经输出权重 V 与 softmax 得到对全词表的预测分布

$$\hat{y}_t = \text{softmax}(V h_t)$$

4. 概率解释：词表中第 k 个词为下一个词的概率

$$P(w_{t+1} = k \mid w_{1:t}) = \hat{y}_t[k],$$

整句概率：各步预测概率连乘： $\prod_{i=1}^n \hat{y}_i[w_i]$ 。

RNN语言模型训练

自监督学习：直接利用原文序列进行训练，无需额外标注；


损失函数：在每个时刻对下一词 w_{t+1} 的负对数概率作为交叉熵损失：

$$L_{CE}(t) = -\log \hat{y}_t[w_{t+1}]$$

Teacher Forcing：训练过程中**始终使用真实前序词作为下一步输入**，而非模型预测，以加速收敛；

优化方式：通过梯度下降最小化平均交叉熵损失，端到端更新参数。

$$L = \frac{1}{T} \sum_{t=1}^T L_{CE}(t)$$



权重绑定

使用RNN构建语言模型时，假定隐藏层的维度与词嵌入的维度相同 (即, d)，输入嵌入矩阵 E ($d \times |V|$) 与输出层权重矩阵 V ($|V| \times d$) 维度相同且语义相似，原因如下：

E 的每一列对应一个词语的词嵌入向量， Vh 计算的结果是词表中每一个词语的logit得分， V 的每一行对应词表中的一个词语。因此， V 相当于 是RNN语言模型学到的第二个词嵌入矩阵。

为避免冗余和提高训练效率，可省去参数矩阵 V ，使用词嵌入矩阵代替，即，在输入层使用词嵌入矩阵 E ，在输出层使用词嵌入矩阵的转置 E^T 。

方法： 让两者共享同一矩阵（输出时取其转置），即 $\hat{y}_t = \text{softmax}(E^T h_t)$ ，同时输入映射仍为 $e_t = E x_t$ 。

效益： 在减少参数量的同时通常也能进一步降低模型困惑度。

序列标注 (Sequence Labeling)


1. 任务定义：对序列中每个元素（如句子中的每个词）分配一个标签。例如，词性标注需从标签集（如NOUN、VERB等）中为每个词选择最优标签。

2. 模型结构

- **输入：**每个时刻的词通过预训练词嵌入映射为向量；
- **RNN处理：**依次将词嵌入输送入RNN，生成各时刻的隐藏状态；
- **输出层：**对每个隐藏状态，使用softmax产生对应标签的概率分布；
- **解码：**每时刻取概率最高标签作为预测。

3. 训练与损失：采用交叉熵损失，对每个时刻的标签预测**独立计算并求和** (同语言模型)；整体模型通过反向传播（含时间展开）端到端训练。

4. RNN在NLP任务中的应用



词性标注的目的是从预定义的标签集中，为句子中的每个词语分配一个对应的语法标签。（图中例句的标签包括 NNP 代表的专有名词、MD 代表的情态动词等）。在处理过程中，模型在每个时间步以预训练的词嵌入作为输入，并通过 softmax 层输出当前词属于各个词性标签的概率分布。


序列分类 (Sequence Classification)

1. 任务定义：对整个文本序列生成一个整体标签，如情感分析（正/负面）、主题分类或垃圾邮件检测。

2. 模型结构

- 序列输入同上，逐词生成隐藏状态；
- 最后时刻隐状态 h_n 或所有时刻隐状态池化作为整句表示；
- 将该表示输入至前馈神经网络，最终经softmax输出序列级类别概率。

3. 训练与损失：仅对序列级输出计算交叉熵损失 (同多类别逻辑回归)，误差信号通过前馈分类器及整个RNN网络端到端反向传播。



文本生成 (Generation with RNN Based Language Models)


1. 任务定义：基于已生成词或给定上下文，逐步生成后续文本。

2. 自回归生成 (Autoregressive Generation) 流程

- 以特定起始符 (如 “<s>”) 为第一输入，计算隐藏状态并通过softmax抽样或贪心地选择下一个词；
- 将该词的嵌入作为下一时刻输入，迭代以上过程；
- 直至达到长度阈值或生成结束符 (“</s>”)。

3. 模型训练


- 与语言建模一致，使用Teacher Forcing：训练时每步输入真实前序词；
- 计算每步对下一个词的交叉熵损失并平均，端到端优化所有参数。



Stacked RNNs（多层堆叠循环网络）

1. 定义：将多个循环网络按层级串联起来，前一层的输出（即隐藏状态序列 h ）将直接作为后一层的输入序列。最终的预测结果 y 仅由最顶层生成。

2. 结构示意图



上图中，在三层堆叠的架构里：第一层 RNN 处理原始输入序列 x ；第二层以第一层生成的隐藏状态序列为输入；第三层再以第二层的隐藏状态序列为输入，并最终输出预测结果 y_t 。

Bidirectional RNNs (双向循环网络)

1. 定义: 同时训练两个方向相反的RNN, 一个从序列开头向末尾遍历 (正向), 一个从末尾向开头遍历 (反向), 在每个时刻将二者的隐状态拼接或融合。

2. 公式


$$\begin{aligned}h_t^f &= \text{RNN}_{\text{forward}}(x_1, \dots, x_t), \\h_t^b &= \text{RNN}_{\text{backward}}(x_t, \dots, x_n), \\h_t &= [h_t^f; h_t^b] \quad (\text{或 } \oplus).\end{aligned}$$

将正向隐状态 h_t^f 与反向隐状态 h_t^b 拼接 (concatenation), 形成新的双向表示。

3. 优点

- 全上下文感知: 对当前时刻的预测, 可同时利用左右两侧的信息, 显著提升标注和分类任务的准确性;
- 应用扩展: 在序列标注任务中, 每个词的标签决策均可参考后续词汇。在序列分类中, 可将前后两个方向的最终隐状态拼接后再分类, 避免单向RNN对末尾信息过度偏重。

5. 堆叠和双向RNN架构



正向和反向分别训练两个独立的模型，并在每个时间步将两者的输出进行拼接（Concatenate），以此作为该时刻的双向状态表示。

三类门及其计算

所有门单元均采用“线性变换→Sigmoid”产生[0,1]范围的掩码，再与相应向量做逐元素乘法，以控制信息流：

1. 忘记门 (Forget Gate)



$$f_t = \sigma(U_f h_{t-1} + W_f x_t), \quad k_t = c_{t-1} \odot f_t$$

用以删除先前细胞状态中不再需要的信息。

2. 新增信息门 (Input/Add Gate)

$$g_t = \tanh(U_g h_{t-1} + W_g x_t), \quad i_t = \sigma(U_i h_{t-1} + W_i x_t), \quad j_t = g_t \odot i_t$$

计算当前时刻应当写入细胞的新信息。



3. 细胞状态更新



$$c_t = k_t + j_t$$

将保留信息和新增信息合并，形成新的细胞状态。

4. 输出门 (Output Gate)

$$o_t = \sigma(U_o h_{t-1} + W_o x_t), \quad h_t = o_t \odot \tanh(c_t)$$

决定哪些细胞状态将影响当前隐藏状态输出。



仔细观察上面的计算公式，输入，都是 x_t 和 h_{t-1} ，细胞状态 c 的作用就像一个传送带，传送着序列历史信息，并通过三个门控机制决定每个时刻 t 如何删除、新增、输出信息。

单元运算总结

每个LSTM单元输入当前外部输入 x_t 、上一步隐藏状态 h_{t-1} 及上一步细胞状态 c_{t-1} ，经过三类门的并行运算后，输出新隐藏状态 h_t 与新细胞状态 c_t 。





Figure 8.13 A single LSTM unit displayed as a computation graph. The inputs to each unit consists of the current input, x , the previous hidden state, h_{t-1} , and the previous context, c_{t-1} . The outputs are a new hidden state, h_t and an updated context, c_t .


模块化与实际应用

- **高度模块化**: LSTM单元内部封装复杂门控逻辑, 对上层网络保持“黑盒”接口;
- **灵活替换**: 可直接替换任何RNN单元, 用于堆叠或双向RNN架构中;
- **主流标准**: 由于其在长距依赖建模和梯度稳定性方面的显著优势, LSTM已成为现代序列建模的默认单元。




用于前馈网络、简单循环网络 (RNN) 以及长短期记忆网络 (LSTM) 中的基础神经单元


7. NLP中常见RNN架构总结




a) sequence labeling



b) sequence classification



c) language modeling




d) encoder-decoder

在序列标注（词性标注或命名实体识别）中，将每个输入词元 x_i 映射为一个输出词元 y_i 。在序列分类中，将整个输入序列映射为单一类别。在语言建模中，基于先前的词元来输出下一个词元。在编码器-解码器模型中，有两个独立的 RNN 模型，其中一个将输入序列 x 映射为“上下文（Context）”，第二个模型则将该上下文映射为输出序列 y 。

Encoder-Decoder模型的基本概念

任务描述：Encoder-Decoder模型主要用于处理输入序列与输出序列长度不一致且映射关系复杂的任务，尤其适用于机器翻译等任务。与传统的序列标注任务（如词性标注）不同，Encoder-Decoder模型的输入序列与输出序列的长度不匹配，且每个输入词与输出词之间没有简单的一一对应关系。

应用领域：该模型广泛应用于机器翻译、文本摘要、问答系统和对话生成等任务。例如，在机器翻译中，输入序列和输出序列不仅可能有不同长度，而且词汇的排列顺序也可能大不相同。



编码器-解码器架构。上下文是输入隐藏表示的函数，且解码器可以以多种方式使用该上下文。

模型结构与工作原理

Encoder-Decoder模型由三个主要部分组成：

- ❶ **Encoder:** 接受输入序列 $x_1, x_2, \dots, x_n$ ，并生成一系列上下文化的表示 $h_1, h_2, \dots, h_n$ ，这些表示捕捉了输入序列的语义信息。Encoder通常使用RNN、LSTM或GRU等网络。
- ❷ **Context Vector:** Encoder的最后隐藏状态 h_n 被用作上下文向量（context vector），这个向量包含了输入序列的核心信息，并传递给Decoder作为生成输出的依据。
- ❸ **Decoder:** Decoder接受Context向量作为输入，并生成一个长度可变的输出序列 $y_1, y_2, \dots, y_m$ ，输出通过Decoder的隐状态和前一时刻的输出生成。


在Encoder-Decoder模型中，给定输入序列 x 下生成目标序列 y 的条件概率计算为：

$$p(y|x) = p(y_1|x)p(y_2|y_1, x)p(y_3|y_1, y_2, x) \dots p(y_m|y_1, \dots, y_{m-1}, x)$$

RNN Encoder-Decoder架构


在基础的RNN Encoder-Decoder模型中：

- **Encoder:** 将输入序列转换为一个上下文表示 (context)，通过一系列的隐状态 $h_1, h_2, \dots, h_n$ 来表征整个输入序列的语义。
- **Decoder:** Decoder在每一步生成一个新的输出 y_t ，每个输出依赖于当前的Decoder隐状态 h_t 和前一步的生成输出。最简单的Decoder版本通过上下文向量初始化其第一个隐状态 h_0 ，然后递归地生成输出。



在基础的基于 RNN 的编码器-解码器机器翻译方法中翻译单个句子（推理阶段）。源句和目标句被拼接在一起，中间带有一个分隔符，并且解码器使用来自编码器最后一个隐藏状态的上下文信息。

8. Encoder-Decoder模型



在基础的基于 RNN 的编码器-解码器架构中，推理阶段翻译句子的更形式化版本。编码器 RNN 的最终隐藏状态 h_n^e 作为解码器的上下文，充当解码器 RNN 中的 h_0^d ，并且该上下文也可供每一个解码器隐藏状态使用。


Encoder通过对输入序列的处理，生成一个上下文向量 c ，它总结了整个输入序列的语义信息。这个上下文向量 c 会在Decoder的每个步骤中被用来生成输出，确保Decoder对整个输入序列的信息都有所了解：

$$h_d^t = g(y_{t-1}^d, h_{t-1}^d, c)$$

背景: Encoder-Decoder模型的瓶颈问题

- **瓶颈问题**: 在传统的Encoder-Decoder模型中, Encoder将整个输入序列映射到一个固定的上下文向量 (**context vector**), 通常是Encoder最后一个时间步的隐藏状态 h_n 。这个上下文向量必须总结输入序列的所有信息, 以便Decoder使用它来生成目标序列。然而, 这种做法存在局限性, 尤其是对于长句子, **输入序列的早期信息可能无法充分传递给Decoder**。

- **解决方案**: 为了解决这一瓶颈问题, 引入了Attention机制, 该机制使得Decoder能够从Encoder的所有隐藏状态中获取信息, 而不仅仅是最后一个隐藏状态。




要求上下文 c 仅仅是编码器的最终隐藏状态, 会迫使整个源句子的所有信息都必须穿过这一表征瓶颈。

Attention机制的工作原理

- **动态上下文向量**：与传统的Encoder-Decoder模型不同，**Attention机制**中的上下文向量不再是固定的，而是根据**Decoder**当前的状态动态生成。具体来说，每个时间步的上下文向量 c_i 是Encoder所有隐藏状态的加权平均。

- **计算方法**：上下文向量 c_i 的生成依赖于Decoder当前的隐藏状态 h_d^{i-1} 和Encoder的所有隐藏状态 $h_e^1, h_e^2, \dots, h_e^n$ ，通过计算每个**Encoder**隐藏状态与当前**Decoder**隐藏状态之间的相关性（点积相似度），得到加权系数。



注意力机制使得解码器的每一个隐藏状态都能看到（获取）一个不同的、动态的上下文，该上下文是所有编码器隐藏状态的函数

计算相关性与加权平均

- **相关性评分**: 在每一步解码时, 通过计算Decoder当前隐藏状态 h_d^{i-1} 与每个Encoder隐藏状态 h_e^j 之间的相关性来确定关注的区域。最简单的计算方法是点积注意力, 通过计算两个向量的点积来度量它们的相似性:

$$\text{score}(h_d^{i-1}, h_e^j) = h_d^{i-1} \cdot h_e^j$$

这个点积结果表示Decoder和Encoder在当前时刻的相关性。

- **归一化与加权**: 将这些相关性分数通过softmax归一化, 得到加权系数 α_{ij} , 这些系数表示每个Encoder隐藏状态对当前Decoder状态的重要性。然后, 通过对所有Encoder隐藏状态加权平均, 计算得到当前的上下文向量 c_i :

$$c_i = \sum_j \alpha_{ij} h_e^j$$

这个上下文向量 c_i 会被用作当前Decoder状态的输入。

$$h_d^t = g(y_{t-1}^d, h_{t-1}^d, c_i)$$

Decoder的更新


- **动态更新**: 每次解码时, Decoder的当前隐藏状态 h_d^i 依赖于之前的隐藏状态 h_d^{i-1} 、当前生成的词 y_{i-1} 以及从 Attention 机制得到的上下文向量 c_i 。具体的更新公式为:

$$h_d^i = g(y_{i-1}, h_d^{i-1}, c_i)$$

其中, g 代表**非线性状态转移函数** (通常由 RNN或LSTM单元实例化)。

- **工程实现**: 在实际网络构建时, 标准 LSTM 仅接收两个物理输入。我们通常在向量维度上将 **当前词嵌入 y_{i-1}** 与**上下文 c_i** 拼接合成一个新的**综合输入向量**, 连同上一状态 h_d^{i-1} 一起送入 LSTM 计算得出 h_d^i 。

9. 注意力 (Attention) 机制



引入注意力机制的 Encoder-Decoder 网络及 c_i 计算示意图

- 动态上下文 c_i : 作为当前步隐藏状态 h^d_i 的核心输入之一。
- 计算机制: 对所有编码器隐藏状态进行加权求和。
- 权重来源: 每个编码器状态的权重, 由它与前一时刻解码器状态 h^d_{i-1} 的点积 (相似度) 决定。

注意力机制扩展

参数化评分函数：除了点积注意力，Attention机制的评分函数还可以采用**基于参数化的加权和**，使网络能够学习在当前应用中，**解码器和编码器状态之间哪些方面的相似性对任务最为重要**，这种注意力机制也称为**双线性注意力**。

$$\text{score}(h_d^{i-1}, h_e^j) = (h_d^{i-1})^T (W_s h_e^j)$$

- **第一步 ($W_s h_e^j$): 特征维度转换。** W_s 相当于一个“特征过滤器与转换器”，将编码器的隐藏状态投影到解码器所需的特征空间中。这一步**允许两者原本的维度不同**。
- **第二步 ($(h_d^{i-1})^T(\dots)$): 计算点积相似度。**将转换后的新特征向量，与当前解码器状态做标准内积，得出最终的相关性得分。

隐藏状态向量 h 中包含了海量的语言特征（比如：词性、单复数、时态、情感色彩等）。 W_s 是一个可学习的矩阵，**它相当于一个“特征过滤器与转换器”**， W_s 会把那些重要的特征维度在矩阵乘法中放大，把不重要的维度缩小。

TL; DR: Attention机制解决了传统Encoder-Decoder模型中存在的瓶颈问题，通过动态生成上下文向量，使得**Decoder**能够在每个时间步都关注输入序列中最相关的部分，从而显著提高了生成任务（如机器翻译）的表现。

RNN损失函数与时序反向传播（BPTT）

在RNN中，模型在整个序列上的总损失 L 是所有时间步预测损失的累加：

$$L = \sum_{t=1}^T L_t$$

为求解全局共享参数矩阵（ W, U, V ）的梯度，利用链式法则沿着时间轴反向追溯：

第一步：计算单步输出损失 L_t

在任意时刻 t ，根据模型当前输出 $\hat{y}_t$ 与真实标签 y_t 计算交叉熵损失 L_t ：

$$L_t = - \sum_{k \in \text{Vocab}} y_t[k] \log \hat{y}_t[k]$$

第二步：评估隐藏状态的总误差梯度（误差传播的“桥梁”）

根据多元复合函数求导法则，某时刻隐藏状态 h_t 的总误差梯度 $\frac{\partial L}{\partial h_t}$ ，由当前时刻的直接输出误差与未来时刻的连带间接误差共同决定：

$$\frac{\partial L}{\partial h_t} = \underbrace{\frac{\partial L_t}{\partial h_t}}_{\text{当前时刻的影响}} + \underbrace{\frac{\partial L_{t+1:T}}{\partial h_t}}_{\text{后续时刻的影响}}$$

利用链式法则展开，可改写为经典的**时序递推状态方程**：

$$\frac{\partial L}{\partial h_t} = \frac{\partial L_t}{\partial \hat{y}_t} \cdot \frac{\partial \hat{y}_t}{\partial h_t} + \frac{\partial L}{\partial h_{t+1}} \cdot \frac{\partial h_{t+1}}{\partial h_t}$$

- $\frac{\partial L_t}{\partial \hat{y}_t} \cdot \frac{\partial \hat{y}_t}{\partial h_t}$ ：误差向下流动，衡量 h_t 对当前单步损失 L_t 的直接贡献。
- $\frac{\partial L}{\partial h_{t+1}} \cdot \frac{\partial h_{t+1}}{\partial h_t}$ ：误差向左流动，衡量 h_t 通过历史记忆对未来所有损失的潜在影响。

理解一下 $\underbrace{\frac{\partial L_{t+1:T}}{\partial h_t}}_{\text{后续时刻的影响}}$

回顾一下课件中 RNN 随时间展开的结构图。信息的传递是严格的单行道：

$$h_1 \rightarrow h_2 \rightarrow \cdots \rightarrow h_t \rightarrow h_{t+1} \rightarrow h_{t+2} \cdots$$

这意味着， h_t 根本无法“越级”去直接影响 h_{t+2} 或者 y_{t+2} 。它要想对 $t+1$ 时刻之后的所有未来事件（即 $L_{t+1:T}$ ）施加影响，必须、且只能通过 h_{t+1} 这个唯一的出口。

因为 h_t 对未来总损失 $L_{t+1:T}$ 的影响全部被 h_{t+1} 代理了，所以根据链式求导法则，这部分偏导数可以写成：

$$\frac{\partial L_{t+1:T}}{\partial h_t} = \frac{\partial L_{t+1:T}}{\partial h_{t+1}} \cdot \frac{\partial h_{t+1}}{\partial h_t}$$

对于 h_{t+1} 这个节点来说，整个序列的总损失 L 可以分为两部分：它发生之前的损失 ($L_{1:t}$) 和它参与的损失 ($L_{t+1:T}$)。因为过去的损失 $L_{1:t}$ 与 h_{t+1} 无关（常数求导为0），所以：

$$\frac{\partial L}{\partial h_{t+1}} = \frac{\partial L_{t+1:T}}{\partial h_{t+1}}$$

把这个等式代入上面的链式法则，就得到了**时序递推方程**的第二部分：

$$\underbrace{\frac{\partial L_{t+1:T}}{\partial h_t}}_{\text{对未来的总影响}} = \underbrace{\frac{\partial L}{\partial h_{t+1}}}_{\text{下一时刻的总误差}} \cdot \underbrace{\frac{\partial h_{t+1}}{\partial h_t}}_{\text{状态转移导数}}$$

第三步：求解并更新全局共享参数

一旦通过上一步的递推公式求出了每一个时间步隐藏层的总误差 $\frac{\partial L}{\partial h_t}$ ，就可以直接计算出全局共享参数矩阵（以输入权重 W 和历史权重 U 为例）的整体梯度：

$$\frac{\partial L}{\partial W} = \sum_{t=1}^T \frac{\partial L}{\partial h_t} \cdot \frac{\partial h_t}{\partial W}, \quad \frac{\partial L}{\partial U} = \sum_{t=1}^T \frac{\partial L}{\partial h_t} \cdot \frac{\partial h_t}{\partial U}$$

结合上述内容，理解一下梯度消失和梯度爆炸

假设我们现在有一个长度为 T 的长序列，我们想计算最后一个时刻的损失 L_T 对第一时刻隐藏状态 h_1 的偏导数 $\frac{\partial L_T}{\partial h_1}$ 。

根据链式法则，误差必须一步一步从 T 倒推回 1。这就意味着要把中间所有时刻的状态转移导数全部乘起来：

$$\frac{\partial L_T}{\partial h_1} = \frac{\partial L_T}{\partial h_T} \cdot \frac{\partial h_T}{\partial h_{T-1}} \cdot \frac{\partial h_{T-1}}{\partial h_{T-2}} \cdots \frac{\partial h_2}{\partial h_1} = \frac{\partial L_T}{\partial h_T} \cdot \prod_{k=1}^{T-1} \frac{\partial h_{k+1}}{\partial h_k}$$

现在让我们看看每一个 $\frac{\partial h_{k+1}}{\partial h_k}$ 长什么样。根据 RNN 的前向计算公式 $h_{k+1} = g(Uh_k + Wx_{k+1})$ ，对它求导会得到：

$$\frac{\partial h_{k+1}}{\partial h_k} = U \cdot g'$$

注：这里为了便于直观理解，我们暂且把矩阵 U 和激活函数导数 g' 简化为标量相乘的形式。

这就意味着，要把误差从 T 传回 1，我们需要把循环权重 U 连乘 $T-1$ 次！

$$\frac{\partial L_T}{\partial h_1} \approx \underbrace{\frac{\partial L_T}{\partial h_T}}_{\text{常数}} \cdot \prod_{t=1}^{T-1} \frac{\partial h_{t+1}}{\partial h_t} = \text{常数} \cdot (U \cdot g')^{T-1}$$

把梯度代入参数更新公式：

$$\frac{\partial L}{\partial U} = \sum_{t=1}^T \frac{\partial L}{\partial h_t} \cdot \frac{\partial h_t}{\partial U}$$

梯度消失（当 $|U \cdot g'| < 1$ 时）：

如果序列长度 $T = 100$ ， $0.9^{100} \approx 0.000026$ 这意味着，第 100 步的误差传导到第 1 步时，已经衰减到几乎为 0 了。这意味着在反向传播时， L_{100} （第100个词预测错误

产生的损失) 对 h_1 没有产生任何有效的纠错信号。当模型试图根据 $t = 1$ 时刻的状态去优化底层权重 U 时, 它完全接收不到来自 $t = 100$ 时刻的反馈。最终导致的结果是: 模型只能根据短期的损失 (比如 L_{99}, L_{98}) 来调整参数, 彻底丧失了学习 “长距离依赖” 的能力。(极其常见)

梯度爆炸 (当 $|U \cdot g'| > 1$ 时):

$1.1^{100} \approx 13780$, 误差会被无限放大, 直接导致计算溢出, 模型崩溃。在梯度下降算法中, 参数更新的步长是: $U_{new} = U_{old} - \text{学习率} \times \text{总梯度}$ 。因为包含着一个极大的子项, 总梯度会瞬间爆炸。这会导致权重矩阵 U 的值被更新到一个极其离谱的位置 (甚至在编程中直接溢出报错, 显示为 **NaN - Not a Number**)。模型不仅学不到任何东西, 原本学到的知识也会在这一次狂暴的更新中瞬间崩溃。

引申: 既然罪魁祸首是 $(U \cdot g')^{T-1}$ 中的连乘, 那么解决梯度消失的终极思路就呼之欲出了——能不能让 $U \cdot g' = 1$? 这正是长短期记忆网络 (LSTM) 的核心机密: LSTM 内部的那条 “细胞状态 (Cell State)” 传送带, 它的状态转移是简单的线性加法 (相当于激活函数 $f(x) = x$, 导数永远是 1), 从而完美避开了连乘衰减。

THE END