第六讲 - 主题模型

张建章

阿里巴巴商学院
杭州师范大学

2024-03-01

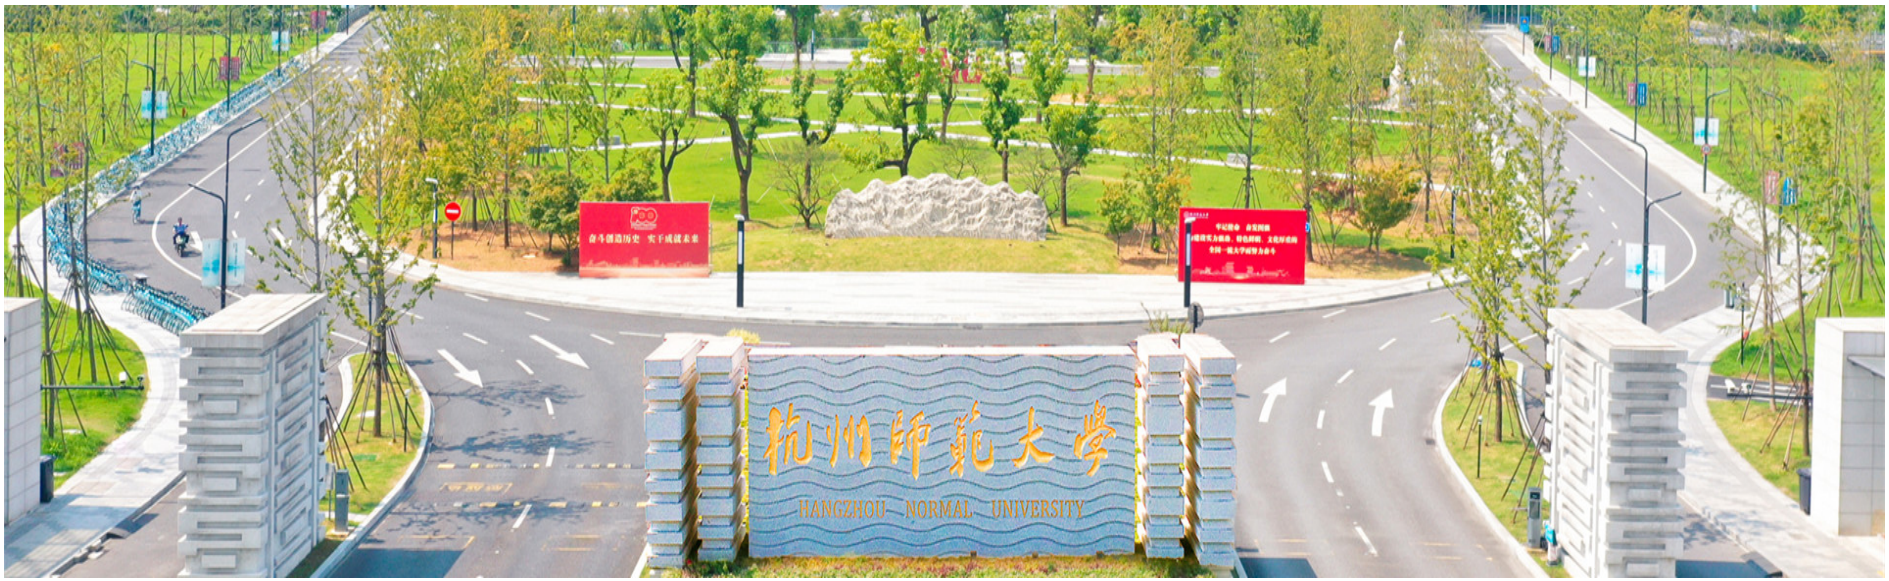

文本主题建模（Topic Modeling）：是一种无监督文本挖掘技术，通过挖掘文档中词语的共现模式，将其映射到一组潜在的主题中，以自动发现和抽取文档集合的主题结构，更好地了解文档集合信息。

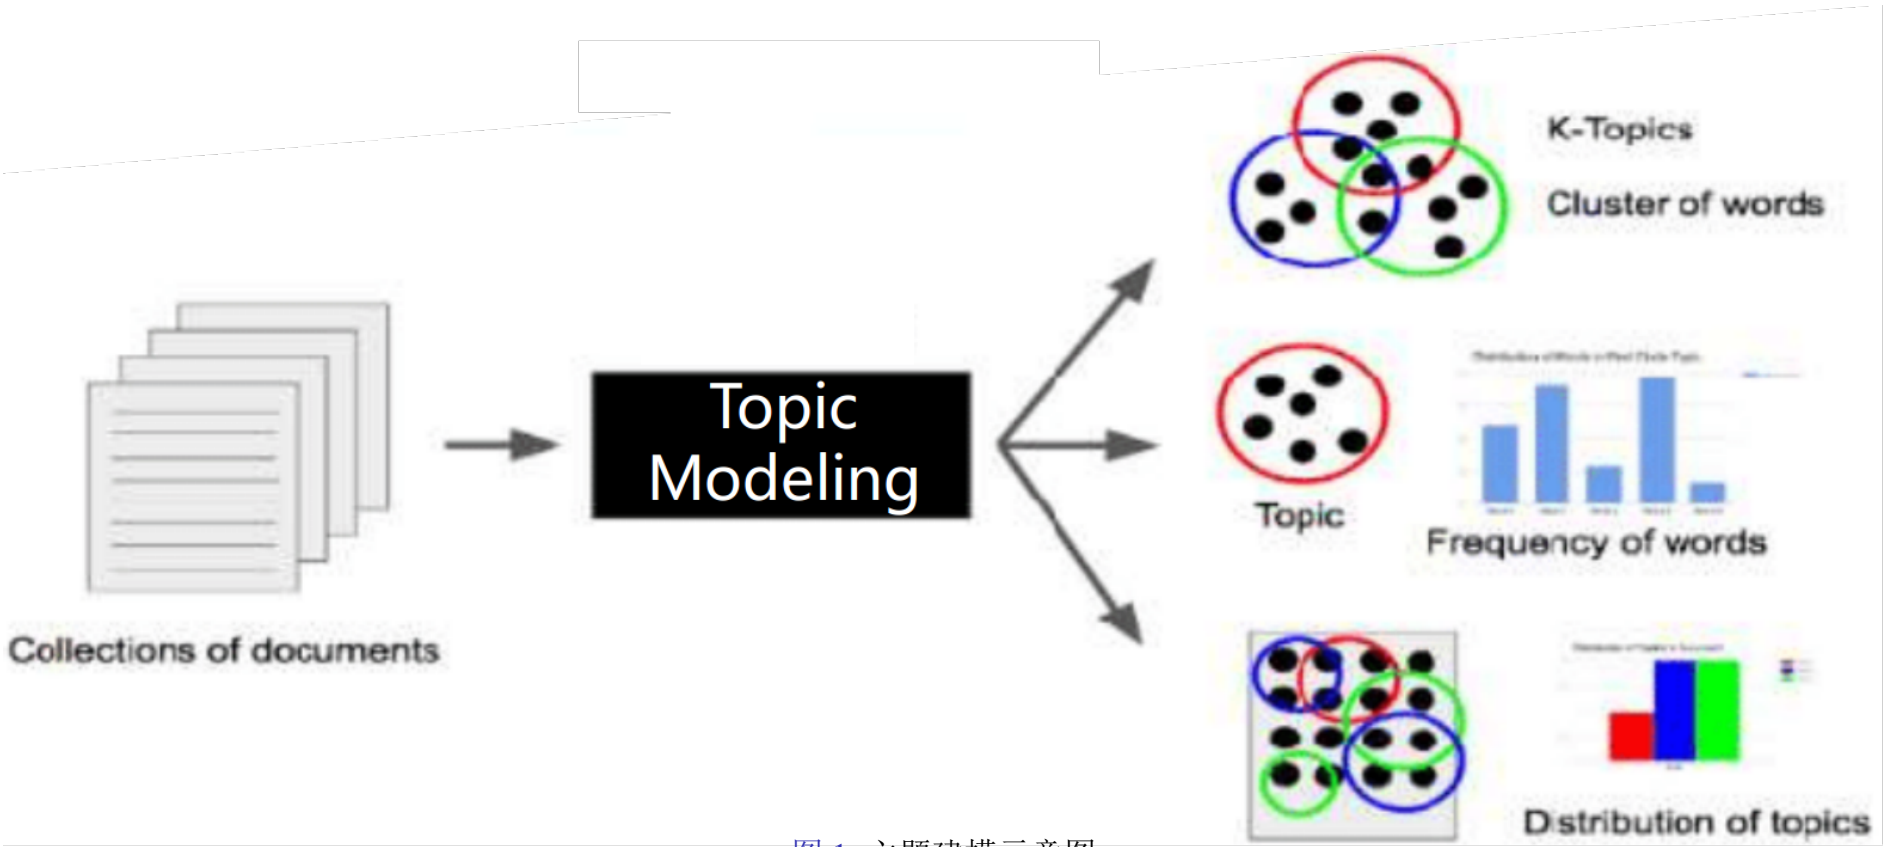

图 1: 主题建模示意图

常用方法有潜在语义索引（LSI）、概率潜在语义分析（pLSA）和潜在狄利克雷分配（LDA）。


Thomas Hofmann


David M. Blei


Andrew Ng

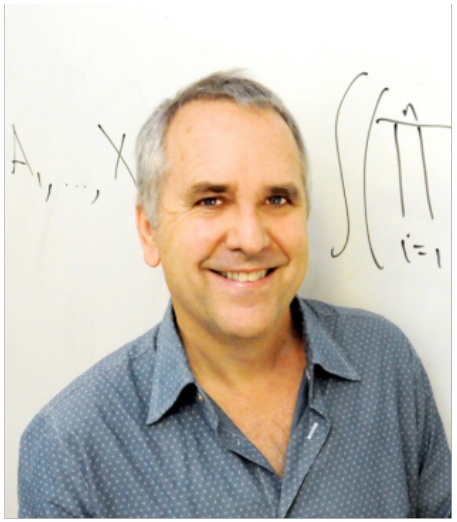
Michael I. Jordan

[1] Hofmann, Thomas. “Probabilistic latent semantic indexing.” Proceedings of the 22nd annual international ACM SIGIR conference on Research and development in information retrieval. 1999.

[2] Blei, David M., Andrew Y. Ng, and Michael I. Jordan. “Latent dirichlet allocation.” Journal of machine Learning research 3, no. Jan (2003): 993-1022.

主题建模与文本聚类的区别

都是无监督文本挖掘方法，从大量文档中挖掘隐藏的结构和主题，主要区别如下：

- **目标：**文本聚类关注将文档分组，而主题模型关注发现潜在的主题结构。
- **输出：**文本聚类的输出是离散的聚类标签，而主题模型的输出是连续的文档-主题分布和主题-单词分布。
- **方法：**文本聚类通常基于距离或相似度度量，而主题模型通常基于概率模型。

在某些情况下可以互相补充，例如，可以使用主题模型的输出（文档-主题分布）作为文本聚类的输入，以发现更具语义信息的簇。

简介

潜在语义索引/分析 (latent semantic indexing/analysis, LSI/LSA)：是一种基于线性代数技术的主题建模方法，使用奇异值分解（SVD）对词语-文档矩阵进行降维，捕捉文档和词项之间的潜在语义结构。

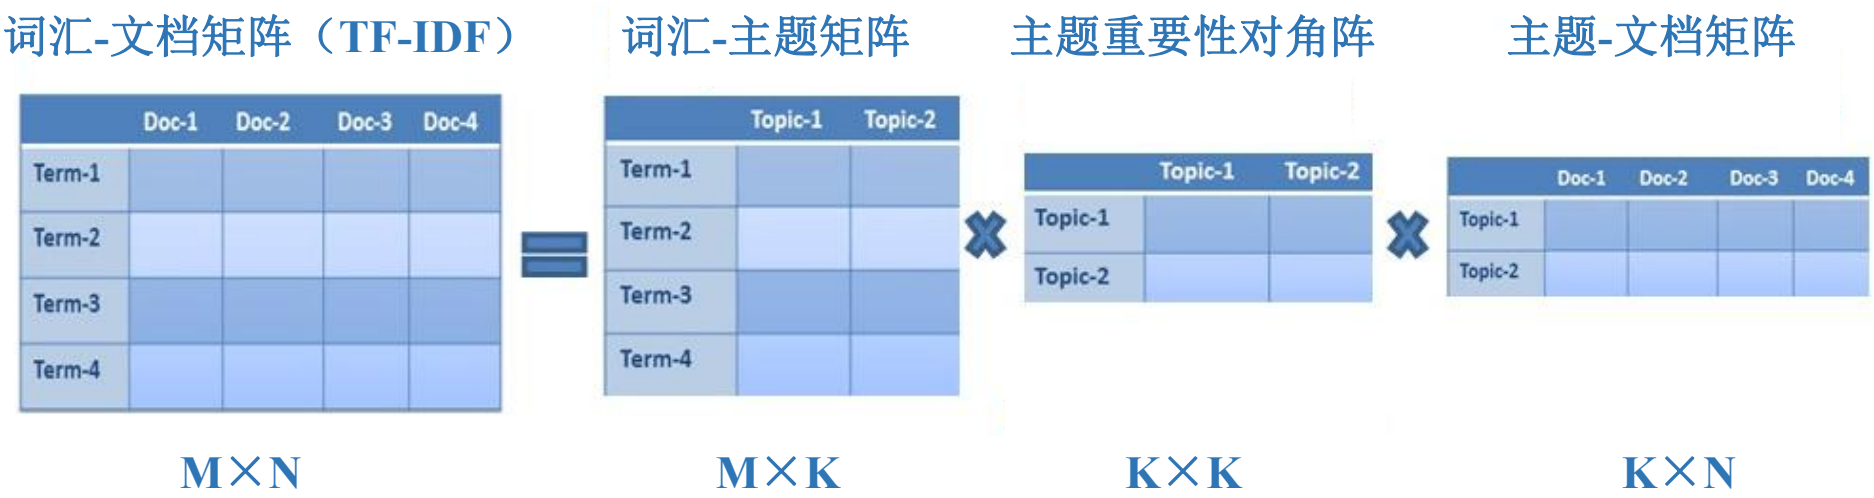

图 2: 潜在语义索引原理示意图

M 为文档集的词表规模，N 为文档数量，K 表示主题数（超参数，提前指定）。基于矩阵分解而非概率统计技术，故矩阵元素为实数，无概率含义，第一个矩阵可视为词汇在潜在主题空间上的向量表示，第三个矩阵可视为文档在潜在主题空间上的向量表示，主题不可解释。

原理-奇异值分解

线性代数中的一种矩阵分解技术，将一个复杂的矩阵分解为几个简单的矩阵相乘。

对于一个给定的 $m \times n$ 矩阵 A，SVD 可以将其分解为三个矩阵的乘积：一个 $m \times m$ 的正交矩阵 U、一个 $m \times n$ 的对角矩阵（只有对角线上有非零元素）Σ 和一个 $n \times n$ 的正交矩阵 V 的转置矩阵 V^T，即：

$$A = U\Sigma V^T$$

矩阵 U 和 V 的列向量是分别是 A 的左奇异向量和右奇异向量，Σ 对角线上的元素是 A 的奇异值，它们都是非负实数，并按降序排列。奇异值反映了数据矩阵 A 中各个方向上的能量或信息量。

LSI 中通过保留矩阵 Σ 中前 k 个较大的奇异值（及对应的 U 和 V 的列向量），可以得到原矩阵 A 的近似表示，从而实现数据的降维和降噪：

$$A \approx U_{m\times k}\Sigma_{k\times k}V^T_{k\times n}$$

简介

概率潜在语义分析 (probabilistic latent semantic indexing/analysis, pLSI/pLSA)：基于概率生成模型的主题建模方法，使用极大似然估计学习文档、词语和主题之间的联合概率分布，核心思想是将每个文档视为主题的混合，每个主题又是词语的概率分布。最终输出两个参数矩阵：

1. 文档-主题概率分布矩阵 $P(c|d)$：行表示文档，列表示主题，每个元素表示主题 c 在文档 d 中的概率。
2. 主题-词汇概率分布矩阵 $P(w|c)$：行表示主题，列表示词语，每个元素表示词语 w 在主题 c 中的概率。

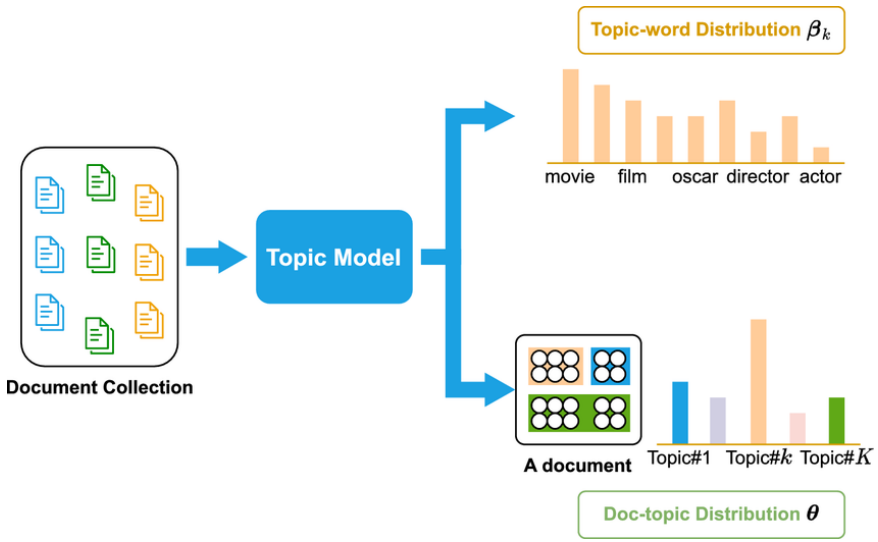

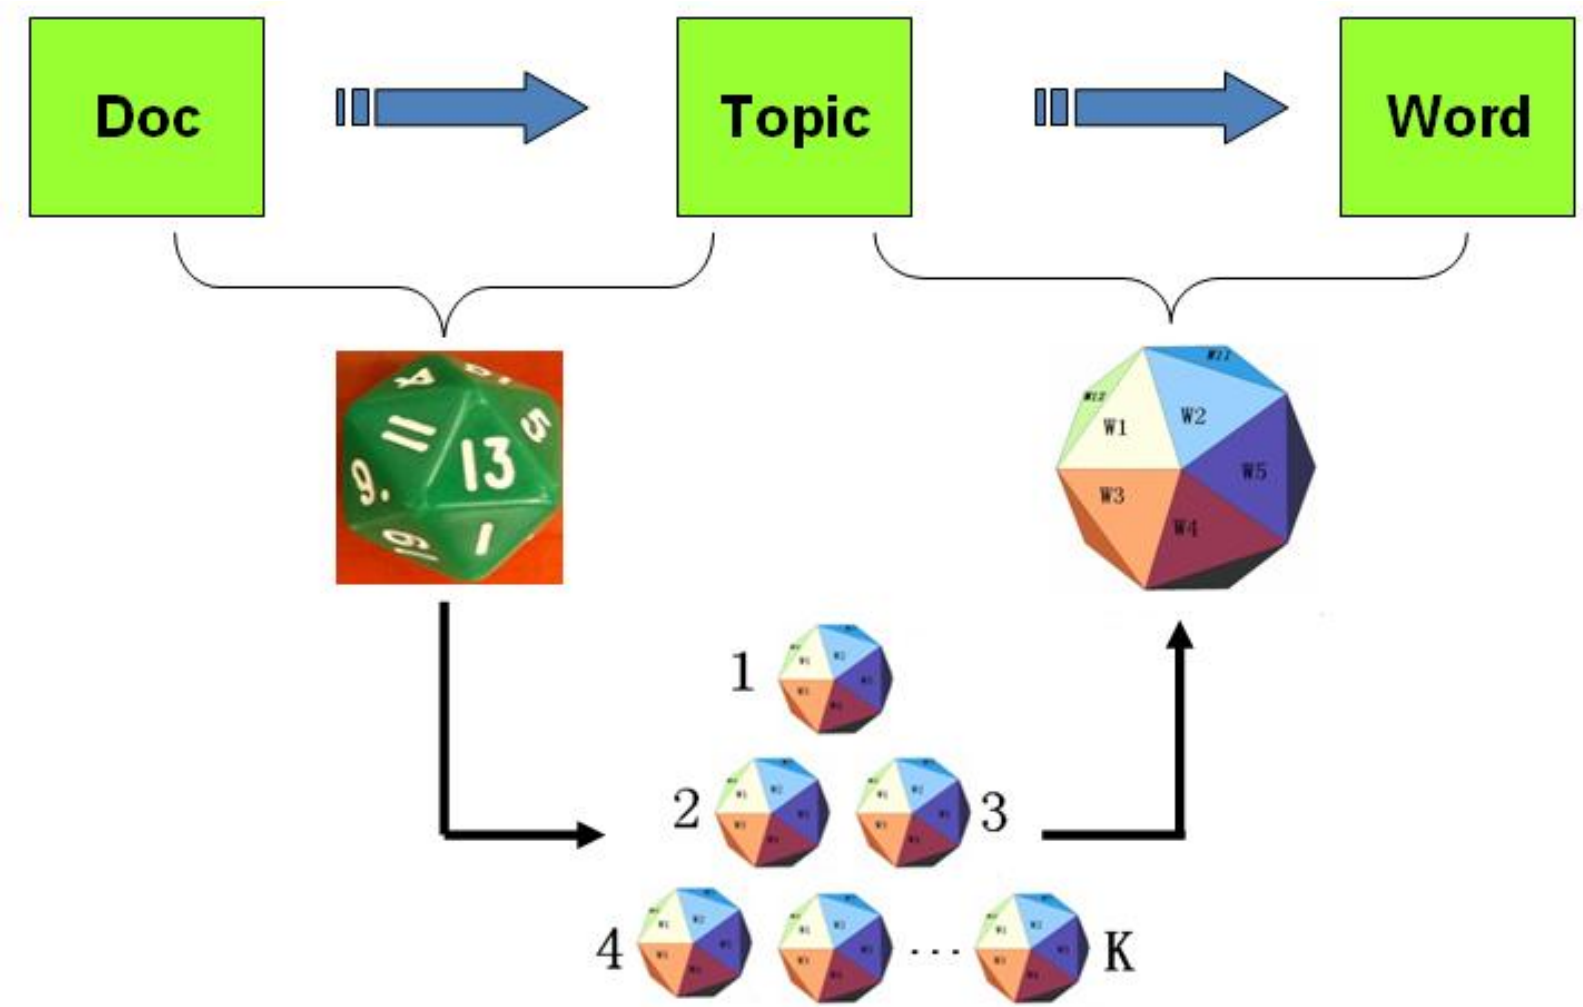

图 3: pLSA 文档生成过程示意图

1: 上帝有两种类型的骰子，一类是doc-topic 骰子,每个doc-topic 骰子有K 个面，每个面是一个topic 的编号；一类是topic-word 骰子，每个topic-word 骰子有V 个面，每个面对应一个词；

doc-topic

topic-word

2: 上帝一共有K 个topic-word 骰子, 每个骰子有一个编号，编号从1 到K；

3: 生成每篇文档之前，上帝都先为这篇文章制造一个特定的doc-topic 骰子，然后重复如下过程生成文档中的词

- 投掷这个doc-topic 骰子,得到一个topic 编号z
- 选择K 个topic-word 骰子中编号为z的那个，投掷这个骰子，于是得到一个词

图 4: pLSA 生成过程通俗解释

原理 - 概率生成模型

前提： 将文档集合视为一组以 (词语, 文档) 形式表示的观测，即 (w, d)。

假设： pLSA 将每个共现的概率建模为条件独立的多项式分布的混合：

$$P(w, d) = \sum_c P(c)P(d|c)P(w|c) \tag{1}$$

由条件独立，可得：

$$\sum_c P(c)P(d|c)P(w|c) = \sum_c P(c)P(wd|c)$$

由全概率公式，可得：

$$\sum_c P(c)P(wd|c) = P(w, d)$$

c 表示主题，主题数为超参数，需提前指定。

式 (1) 为 pLSA 的对称对称表达式，即，词语和文档均由主题以多项式分布生成，对应条件概率 $P(w|c)$ 和 $P(d|c)$。

由条件概率公式，可得 pLSA 的非对称表示形式，如下：

$$P(w,d) = P(d)\sum_{c} P(c|d)P(w|c) \tag{2}$$

即，对于给定的文档 d，以概率 $P(c|d)$ 选择主题 c，并在主题 c 下，以概率 $P(w|c)$ 生成词语 w。

对称与非对称的 pLSA 表示形式的区别，如下图 (Z 表示主题) 所示：

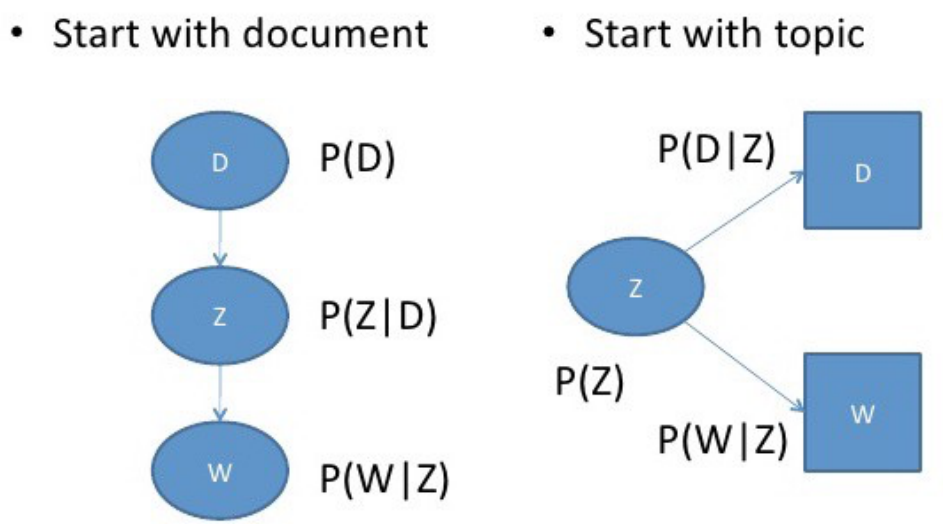

求解：共 $cd + wc$ 个参数，采用期望最大化 (expectation maximization, EM) 算法寻找极大似然估计。

文本挖掘中通常使用 pLSA 的非对称表示形式，其盘式表示法 (plate notation) 如下：

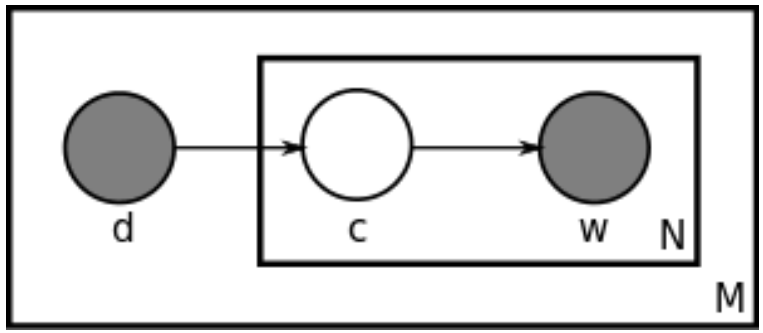

图 5: pLSA 非对称形式的盘式表示法

上图中，M 表示文档数，N 表示词表规模，d 表示单个文档，c 表示单个主题，w 表示单个词语。

pLSA 基于统计推断，其结果向量中的元素表示概率值，而 LSA 结果向量中的元素值为实数，无概率含义。

介绍

潜在狄利克雷分配 (Latent Dirichlet allocation, LDA)：目前最流行的主题建模方法之一，是 pLSA 的贝叶斯扩展，使用狄利克雷先验分布对文档-主题和主题-词项的多项式分布进行建模，通过贝叶斯推断来学习这些多项式分布的后验概率。

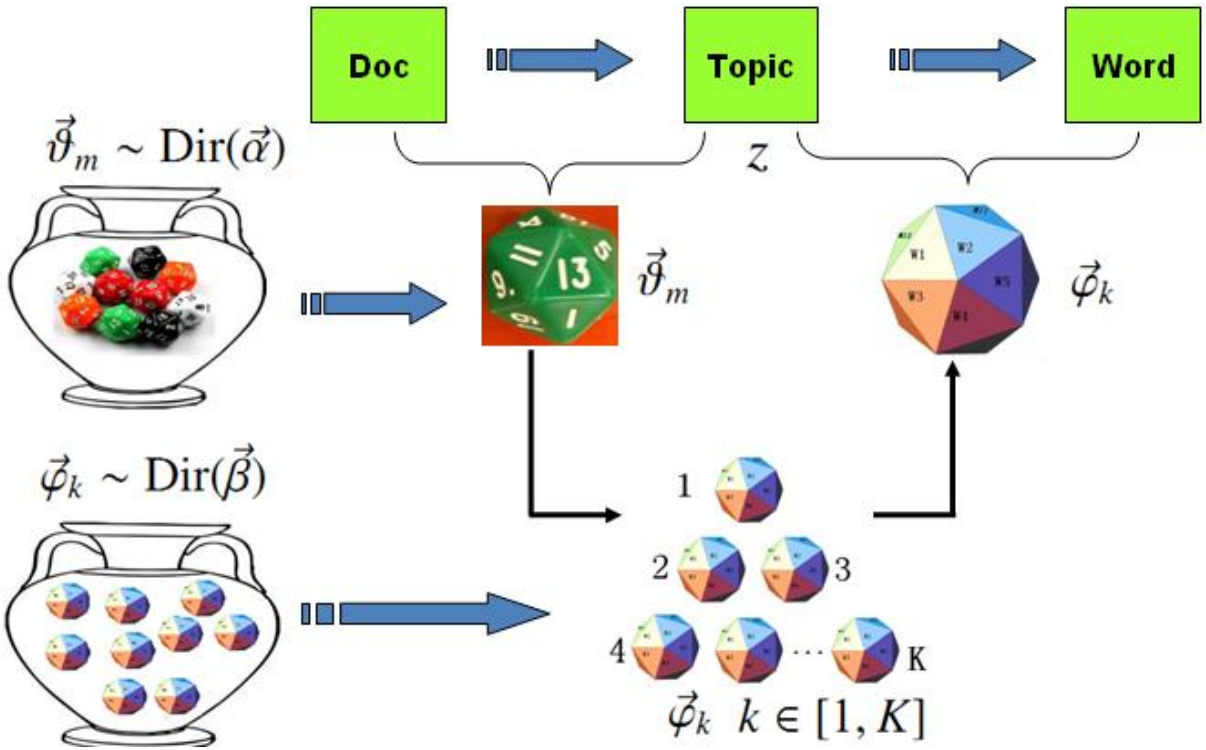

图 6: LDA 文档生成过程示意图

1: 上帝有两大坛子的骰子，第一个坛子装的是doc-topic 骰子,第二个坛子装的是topic-word 骰子；

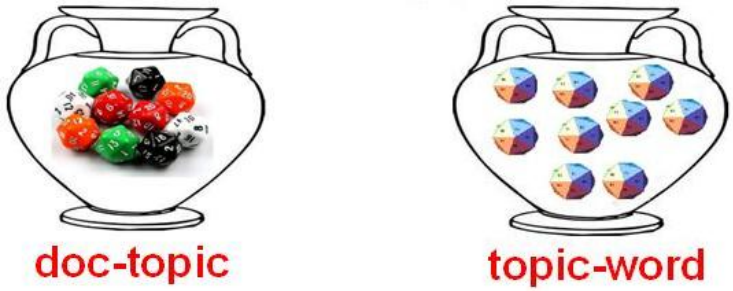

2: 上帝随机的从第二个坛子中独立的抽取了K 个topic-word 骰子，编号为1到K；

3: 每次生成一篇新的文档前，上帝先从第一个坛子中随机抽取一个doc-topic骰子，然后重复如下过程生成文档中的词

- 投掷这个doc-topic 骰子,得到一个topic 编号z
- 选择K 个topic-word 骰子中编号为z的那个，投掷这个骰子，于是得到一个词

图 7: LDA 文档生成过程通俗解释

原理 - 概率生成模型

LDA 对 pLSA 的关键扩展在于使用多项式的共轭先验分布——狄利克雷分布对多项式分布的参数进行贝叶斯参数估计，pLSA 将多项式分布的参数作为常量，而 LDA 将多项式分布的参数作为服从狄利克雷分布的变量，即，把式 (2) 扩展如下：

$$P(w, d) = P(d) \sum_{c} P(c|d; \theta) P(w|c; \phi) \tag{3}$$

其中 θ 和 ϕ 分别表示文档-主题多项式分布和主题-词语多项式分布的参数。盘式表示法如下图，α 和 β 分别为文档-主题多项式分布和主题-词语多项式分布的狄利克雷先验参数。

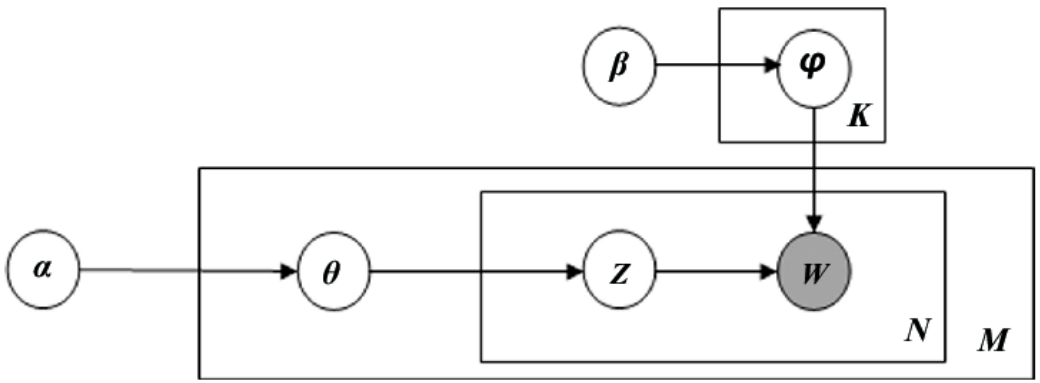

LDA 的前提和假设同 pLSA，参数估计通常采用 Gibbs 采样或变分贝叶斯，LDA 输出结果中的最常用的两个参数矩阵也是文档-主题概率分布矩阵，主题-词语概率分布矩阵。

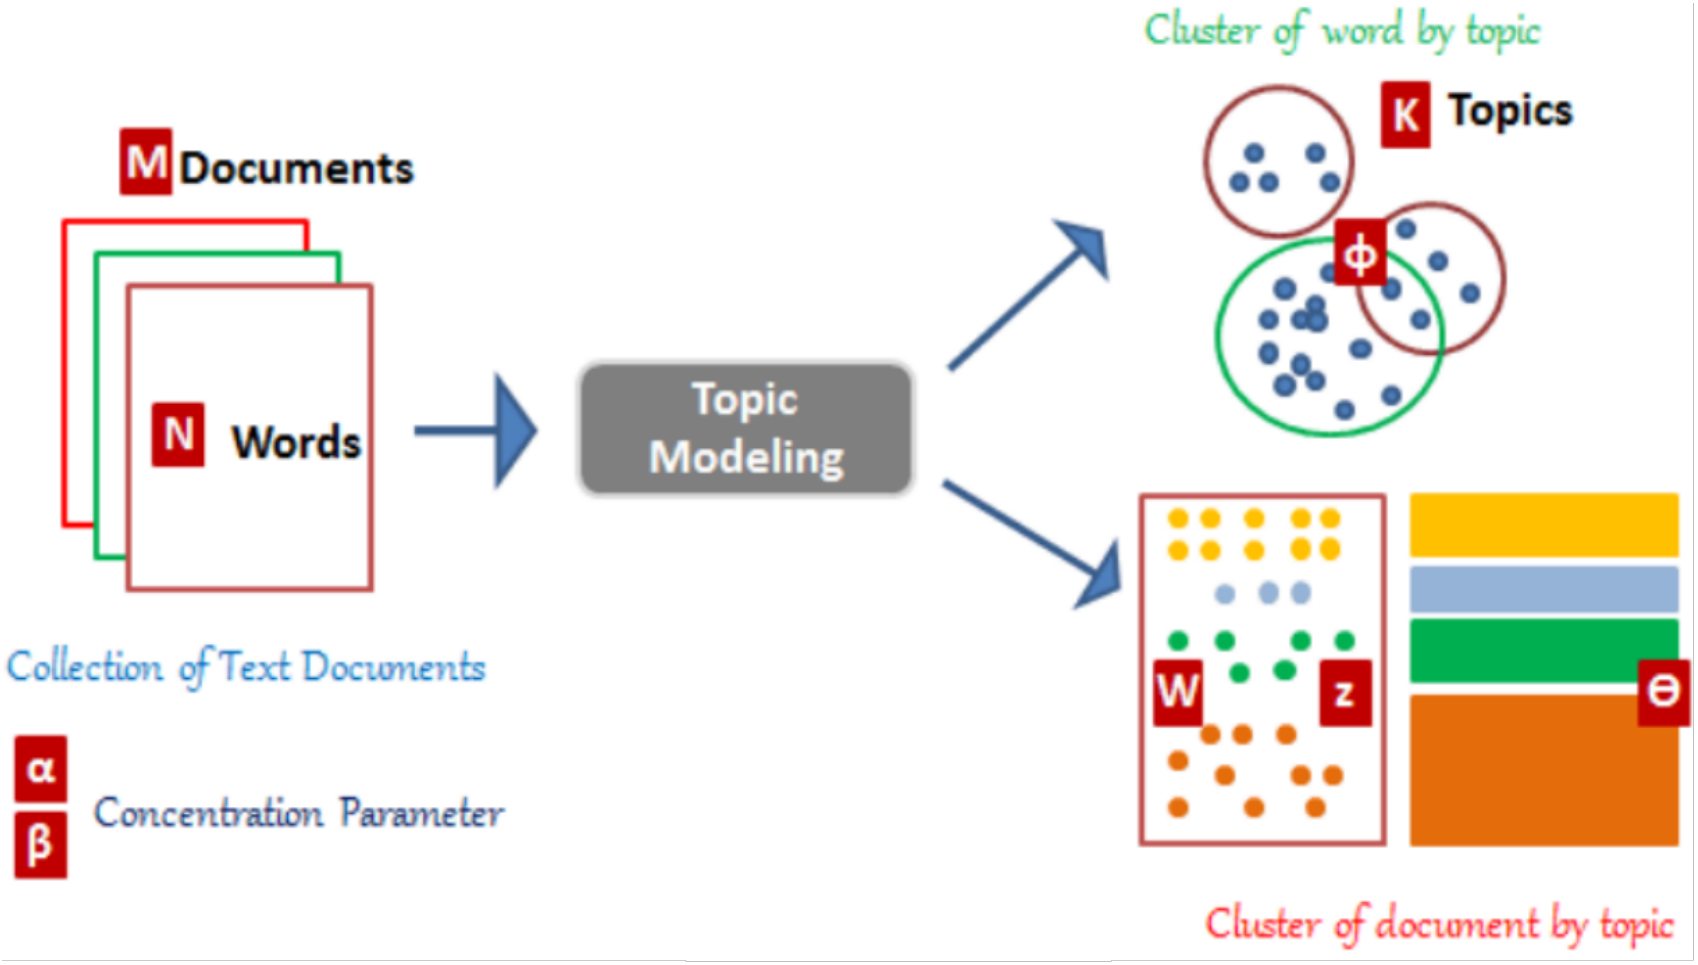

图 8: LDA 文本主题挖掘示意图

困惑度 I

困惑度 (Perplexity) 是衡量主题模型性能的常用指标，反映了模型对新数据的预测能力，值越低表示模型对新数据的预测能力越强，可以理解为测试数据的对数似然（log-likelihood）的负指数化，计算原理如下：

$$\text{Perplexity}(D) = \exp\left(-\frac{\sum_{d=1}^{|D|} \log p(w_d)}{N}\right)$$

其中：

- D 是测试文档集;
- $|D|$ 是测试文档的数量;
- N 是所有测试文档中的词语总数;
- w_d 是第 d 个文档;
- $p(w_d)$ 是文档 d 的词语的生成概率。

困惑度 II

对于 LDA 模型，困惑度可以通过以下方式计算：

1. 计算每个文档的似然：

- 每个文档 d 的似然 $p(w_d)$ 是文档中所有词语似然的乘积。对于文档 d 中的每个词 w，其似然可以通过 LDA 模型的参数 (文档-主题分布和主题-词分布) 来计算:

对于文档 d，其生成概率 $p(w_d)$ 可以表示为文档中所有词语的联合概率：

$$p(w_d) = \prod_{n=1}^{N_d} p(w_{d,n})$$

每个词语 $w_{d,n}$ 的概率 $p(w_{d,n})$ 是该词在所有主题中的概率加权平均 (全概率公式)：

困惑度 III

$$p(w_{d,n}) = \sum_{k=1}^{K} p(w_{d,n}|z_{d,n} = k)p(z_{d,n} = k|d)$$

- $p(w_{d,n}|z_{d,n} = k)$ 是词 $w_{d,n}$ 在主题 k 中的概率，可从主题-词分布矩阵中获取;

- $p(z_{d,n} = k|d)$ 是主题 k 在文档 d 中的概率，可从文档-主题分布矩阵中获取;

2. 计算总体似然：

- 总体似然是所有文档似然的和;

3. 平均对数似然：

- 平均对数似然是总体对数似然除以文档中词语的总数 N;

4. 计算困惑度：困惑度是平均对数似然的负指数化。

根据困惑度值选择恰当的主题数 I

困惑度随主题数变化的趋势:

① 通常情况下，困惑度会随着主题数的增加而降低。因为更多的主题数提供了更多的自由度来解释数据，导致模型对训练数据的拟合变得更好；

② 当增加主题数时，困惑度的下降幅度会逐渐减小，找到困惑度下降减缓的拐点可以帮助选择一个合适的主题数；

③ 选择一个困惑度较低但主题数不至于太大的模型，可以平衡模型的复杂度和在新数据上的表现，在选择主题数时，不仅要考虑困惑度，还要考虑主题的解释性，确保选择的主题数能够生成有意义且易于解释的主题。

主题一致性 I

主题一致性：评价主题模型生成的主题质量的常用指标，通过计算主题词在文档中的共现频率，评估主题词之间的语义一致性，一种常用的主题一致性指标 `c_v` [12]的计算过程如下：

1. 提取主题词

从每个主题中提取权重最大的前 N 个词。

2. 构建词对共现矩阵

使用滑动窗口的方法在原始文档中统计词对的共现频率，共现矩阵记录了词对在一定窗口大小内共同出现的频率。

3. 计算点互信息 (PMI)

点互信息 (PMI) 用于衡量词对的共现关联性。对于每对词 w_i 和 w_j，PMI 的计算公式为：

$$\text{PMI}(w_i, w_j) = \log \frac{P(w_i, w_j)}{P(w_i)P(w_j)}$$

主题一致性 II

- $P(w_i, w_j)$ 是词 w_i 和词 w_j 在窗口内共同出现的概率;

- $P(w_i)$ 和 $P(w_j)$ 分别是词 w_i 和 w_j 的出现概率。

4. 计算每个主题的一致性得分

对于每个主题，将其所有词对的 PMI 值进行聚合得到主题的一致性得分。具体而言，可以计算每个词对的 PMI 值，然后取平均值或其他统计值。

5. 计算整个模型的一致性得分 c_v

最终，模型的 c_v 值是所有主题一致性得分的平均值。

[1]Röder, Michael, Andreas Both, and Alexander Hinneburg. "Exploring the space of topic coherence measures." In Proceedings of the eighth ACM international conference on Web search and data mining, pp. 399-408. 2015.

[2]https://radimrehurek.com/gensim/models/coherencemodel.html

主题差异性

主题差异性衡量主题之间的不同程度，一个简单的度量方式是计算每个主题的前 n 个词的唯一词比例。

$$\text{Topic Diversity} = \frac{\text{Number of Unique Words in Top-n Terms}}{K \times n}$$

其中，K 是主题的数量。

人工评价

尽管自动化评价指标很重要，但人类评价仍然是主题模型评价的关键部分。通过人工检查主题词的质量和对实际问题的解释能力，可以获得模型的真实表现。

总结: 在实际应用中，通常需要结合多种指标来全面评估 LDA 模型的效果。困惑度和对数似然适用于衡量模型的整体表现，而主题一致性和主题差异性则帮助评估主题的质量和区分度。结合人类评价，可以更准确地选择和调整主题模型。

1 - 加载所需软件包和数据集

```
import numpy as np
import re
import gensim
from gensim import corpora
from sklearn.datasets import fetch_20newsgroups
import pyLDAvis
import pyLDAvis.gensim_models as gensimvis
import nltk
from nltk.corpus import stopwords


# 加载数据集
newsgroups = fetch_20newsgroups(subset='all', remove=('headers',
↪  'footers', 'quotes'))
```

2 - 预处理文本数据

```
# 下载英文停用词
nltk.download('stopwords')
stop_words = set(stopwords.words('english'))
def preprocess(text):
  text = re.sub(r'\W', ' ', text)  # 移除非单词字符
  text = re.sub(r'\s+', ' ', text)  # 移除多余空格
  text = text.lower().strip()
  words = text.split()
  words = [word for word in words if word not in stop_words and
  ↪  len(word) >2]  # 移除停用词
return words

documents = [preprocess(document) for document in
↪  newsgroups.data]

# 创建字典和语料库
dictionary = corpora.Dictionary(documents)
corpus = [dictionary.doc2bow(document) for document in documents]
```

3 - 训练主题模型

```
# 指定主题数量
num_topics = 20

# 训练 pLSA 模型
lsi = gensim.models.LsiModel(corpus, id2word=dictionary,
↪  num_topics=num_topics)

# 显示主题-pLSA
topics = lsi.print_topics(num_topics=num_topics)
for topic in topics:
  print(topic)
```

4 - LDA 结果可视化

```
# 训练 LDA 模型
lda = gensim.models.LdaModel(corpus, id2word=dictionary,
↪  num_topics=num_topics, random_state=2023)

# 显示主题-LDA
topics = lda.print_topics(num_topics=num_topics)
for topic in topics:
  print(topic)

# 准备 LDAvis 数据
lda_vis_data = gensimvis.prepare(lda, corpus, dictionary)

# 可视化
pyLDAvis.display(lda_vis_data)
```

4 - LDA 结果可视化

从下图右侧的主题-词汇分布可知，该主题为“太空探索”相关。

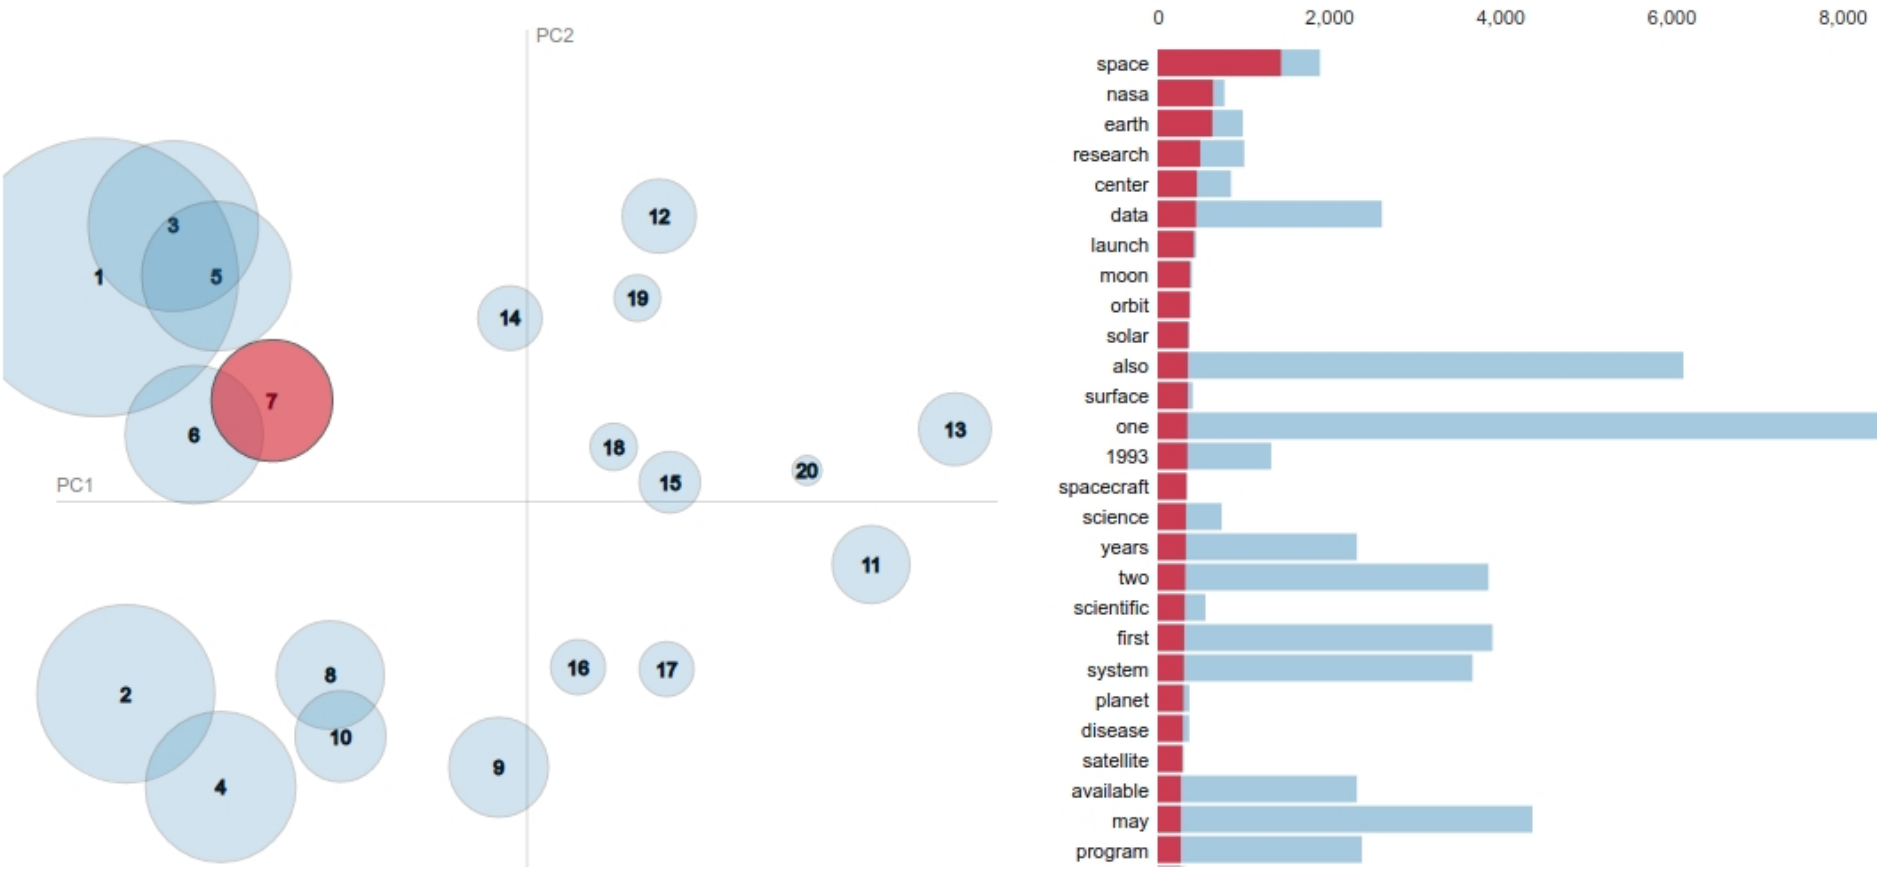

图 9: LDA 主题建模结果可视化示例

1. 使用本课程提供的中文新闻语料库，使用 gensim 中的文本主题建模方法进行主题挖掘，具体要求如下：

① 自行查找资料学习主题挖掘结果定量度量指标；

② 绘图对比不同主题建模方法结果的定量指标，横轴为主题数 K，纵轴为所选取的定量指标；

③ 学习使用 `BERTopic` (主页)包进行主题建模；

THE END